T.C. SANAYİ VE TEKNOLOJİ BAKANLIĞI

#MİLLİ TEKNOLOJİ HAMLESİ

TÜBİTAK

RAG SİSTEMLERİNE GİRİŞ

ARAŞTIRMA SERİSİ - SAYI 19



BİLGEM

YAZILIM TEKNOLOJİLERİ ARAŞTIRMA ENSTİTÜSÜ

Simge ve Kısaltmalar

Kısaltmalar	Açıklama
TÜBİTAK	Türkiye Bilimsel ve Teknolojik Araştırma Kurumu
BİLGEM	Bilişim ve Bilgi Güvenliği İleri Teknolojiler Araştırma Merkezi
YTE	Yazılım Teknolojileri Araştırma Enstitüsü
BDM	Byte-Pair Encoding (Bayt Çifti Kodlaması)
BERT	Bidirectional Encoder Representations from Transformers (Transformatörlerden Çift Yönlü Kodlayıcı Temsiller)
BPE	Büyük Dil Modelleri
RAG	Retrieval-Augmented Generation (Edinim Artırımlı Üretim)

Yazar
Sedat YILMAZ

Yayın Koordinatörü
Kübra ERTÜRK

Editörler
Eyüp Halit YILMAZ
Fatih İNCE
Beyza ŞENEL
Tuğçe YILMAZ

Tasarım
Şeyma KOÇER

©2024 - Tüm hakları saklıdır.

İletişim: 0(312) 289 92 22 - yte.bilgi@tubitak.gov.tr

https://bilgem.tubitak.gov.tr/yte/

Yayınlanan yazıların sorumluluğu yazarına aittir, TÜBİTAK BİLGEM sorumlu tutulamaz.

İçindekiler

Ön Söz 4

Giriş 5

Dil Modellerinde Üretim 6

- Edinim Artırımlı Üretimin Kullanılma Gerekçesi 8

Edinim Artırımlı Üretim 8

- Edinim Artırımlı Üretim Aşamaları 9
  - Edinim Kaynaklarının Hazırlanması 9
  - Alakalı Bölümlerin Tespiti 10
  - Yeniden Sıralama (Reranking) 10
  - Modele Sunum 11
- Uygulama Örneği 11
  - Çıktı Üretim Süreci 12
    - Edinim Artırımsız Cevaplar 13
    - Edinim Artırımlı Cevaplar 15
  - Çıktı Değerlendirmesi 17

Sonuç ve Öneriler 18

Kaynakça 19

Ön Söz

TÜBİTAK BİLGEM Yazılım Teknolojileri Araştırma Enstitüsü (YTE), 2012 yılından bu yana yazılım teknolojilerinde Ar-Ge faaliyetleri yürüten bir araştırma kuruluşudur. Araştırma faaliyetlerinde elde ettiği birikimini stratejik, hassas ve kritik projeler yürüterek kamu adına hayata geçirmekte; kurumlarımıza dijital dönüşüm, yazılım geliştirme teknolojileri ve kalite süreçleri konusunda danışmanlık vermektedir.

TÜBİTAK BİLGEM YTE tarafından hazırlanan Araştırma Serisi ile kurum içi içerik üretme çalışmalarının yaygınlaştırılması ve hazırlanan içeriklerin sektörün erişimine açılması amaçlanmaktadır. Araştırma Serisi'nde yayınlanan çalışmalar TÜBİTAK BİLGEM YTE çalışanlarının projelerde elde ettiği bilgi birikimini paylaşmak adına derlenmiştir. Bu çalışmalar ile ülkemizin yazılım sektörüne katkı sağlanılması hedeflenmektedir.

Giriş

Çağımızın en önemli teknolojilerinden biri olan **Büyük Dil Modelleri (BDM)**, dilin bilgisayarlar tarafından işlenilmesindeki en güncel teknolojidir. Başlangıçta dilin doğrudan kural bazlı metin çevirileri, sonrasında tanımlayıcı istatistik ve öncül makine öğrenmesi yöntemleri ile işlenmesi hedeflenmiştir. Bu motivasyon özellikle dilin her yerde olması ve iletişimin temel aracı olması açısından analizinden yüksek fayda edinilebilecek olduğu düşüncesinden gelir. Ancak harflerin ve kelimelerin tekil anlamından öte, birlikte kullanılmalarının getirdiği çok sayıda çeşitlilikten dolayı karar destek sistemlerine istenen katkıyı sağlayamamıştır. Bu çeşitlilik; kelimelerin kullanım sırasının ötesinde eş anlamlı sözcükler, atasözleri, kinayeler gibi günlük hayatta çok sık kullanılan ve yer yer farklı bağlamları bağlayan, yer yer kullanıldığı bağlama göre anlamı değiştiren unsurların da varlığıyla ortaya çıkmaktadır.

Büyük dil modelleri, kendilerinden önceki çabaların temel paradigmalarından farklı paradigmalara sahiptir. Öncesinde yapılan çalışmalar, temelde dil kurallarının bilgisayarlar üzerinden tanımlanması ve metinlerin bu kurallar doğrultusunda çeşitli ön işleme adımlarından geçirilmesi sonucu elde edilen yeni verilere bir takım kural denetimleri yapılması veya sıklık, tanımlayıcı istatistik gibi metnin adeta bir sayı kümesi gibi analiz edilmesine dayanmaktaydı. Bu paradigma, gömme (embedding) modellerinin geliştirilmesiyle değişmeye başladı. Gömme modelleri sayesinde dilin çeşitli ifadelerindeki anlam, vektörler olarak ifade edilebildi. Bu sayede metinlerdeki anlam bilgisayar tarafından daha işlenebilir hale geldi. Öncesinde kelimelerin birlikte kullanım matrisleri üzerinden oluşturulan bu modeller ilerleyen teknoloji ile kelime altı parçalardan oluşturulmaya başlanmıştır. Gömme modelleri sonrasında daha da gelişen dil modelleri, dil bilgisi kurallarının işletilmesi fikrinden vazgeçip, dilin, sırasal modelleme perspektifiyle modellenebilecek bir unsur olduğunu kabul etmiş ve başarılı bir dil modelinin dilbilim kurallarını en iyi işleyen model olmasından çok, dilin kullanım örneklerini en iyi taklit edebilen model olması hedefini kabul etmiştir.

Bu yeni hedef altında günümüz modelleri ele alındığında, dilin çok sayıda kullanım örneği üzerinde eğitim gören dil modellerinin, eğitimleri sonrasında kendisine yönetilen yeni sırasal veriden (prompt) sonra gelebilecek unsurları tahmin etme konusunda oldukça başarılı hale geldikleri söylenebilir.

Metinler, birçok alanda ifadenin temel ortamlarındandır. Günümüzde Büyük Dil Modelleri, görece gündelik ve genel kullanım amaçlarıyla bu modalitede başarılı olabilecek çıktılar üretebilmekte fakat henüz metin üretme problemi, metinlerin kullanıldığı tüm alanlarda istenen başarımlarda çözülebilmiş değildir. Başarılı örnekler incelendiğinde, özgün alanlarda bu tür dil modellerinin çıktılarının kalitesinin artırılmasında birçok yöntem söz konusu olmakla birlikte ince ayarlama (fine tuning) ve edinim artırımlı üretim (ing. retrieval-augmented generation ve bkz: almayla artırılmış üretim) karşımıza çıkmaktadır. Edinim artırımlı üretim, dil modelinin eğitim esnasında sahip olmadığı veriye, çıkarım aşamasında maruz kalmasını sağlayarak, özelleşmiş konularda ürettiği çıktının kalitesini artırmaktadır. Bu yazı, edinim artırımlı üretim perspektifi hakkında giriş seviyede bilgi sunmayı hedeflemektedir.



Dil Modellerinde Üretim

Tarihçesi incelendiğinde, edinimle artırmanın doğal dil modelleriyle bir arada kullanılmasının 2020 yılında University College London, New York University ve o zamanki adıyla Facebook AI Research ekibinin ortak çalışması olarak ortaya çıktığı görülmektedir [1]. Bu çalışmanın temel amacı, edinim ile artırmanın faydasını ortaya koymak olmuştur. Bu faydayı daha iyi anlayabilmek için, önce büyük dil modelleri ile metin üretim süreçlerine bakmak gerekmektedir. Günümüz dil modellerinde çeşitli mimariler bulunmakla birlikte, yaygın olarak kullanılan "transformer" temelli mimariler, metin üretiminde temel olarak üç aşamadan geçerler:

1. Bölütleme (Tokenization): Metinlerin sayılar ile temsil edilmesine yönelik ilk adımdır. Bu sayısallaşma sonucu metinler, bölütler (token) cinsinden ifade edilir. Bölütler, farklı modellerde değişiklik göstermek üzere, günümüz başarılı modellerinde kelime altı uzunluklara sahiptir. Bir modele sunulan ve hakkında veri üretilmesi istenen girdiye "prompt" denir. Modele sunulan prompt, bölütleme işlemiyle sayısallaştırıldıktan sonra kodlayıcı (encoder) aşamasına geçilir. Üretim esnasında promt'un bölütlenmesine ek olarak, bölütleme stratejisi modelin ilk eğitimi için de önemli bir konudur. Bir modelin sahip olabileceği bölüt sayısı ve bölüt büyüklüğünü belirleyen yöntemler model eğitimi öncesinde belirlenen unsurlar olup bölütlerin ne olacağı eğitim verisinin işlenmesiyle belirlenmektedir. Temelde modelin işlediği veri, bölütleme ile üretilmiş sayılar olduğundan modelin metin algısını ve üretimini doğrudan etkileyen bir unsur olup, özellikle sayı ve tarih verisi içeren metinlerde modelin sayıları nasıl bölütlediği modellerin çıktılarına doğrudan etki etmektedir. Yaygın bölütleme stratejileri aşağıdaki gibi olmakla birlikte farklı aktörler kendi modellerinde fayda üreteceğini düşündüğü unsurları içermesi hedefiyle farklı bölütleme yöntemleri de kullanabilir;

   a. **Bayt Çifti Kodlaması (Byte-Pair Encoding [BPE]):** Eğitim verisindeki tüm benzersiz karakterleri oluşturur, sonrasında kullanım sıklıklarına göre bu harfleri birleştirerek kelime altı boyutta bölütler oluşturur.

      i. **Bayt Seviyesinde Bayt Çifti Kodlaması:** Eğitim verisinde bulunmayan bir karakteri "bilinmeyen bölüt" olarak işaretlemektedir. Bu duruma örnek olarak sosyal medyada sık sık karşılaşılan "emojiler" verilebilir. Bu durum metnin bölütlemenin kalitesini düşürebilmektedir. Buna alternatif olarak, BPE algoritmasının harfler yerine bit seviyesindeki veri ile yapılan hali ortaya konmuştur. Bu durum metinde bilinmeyen bölüte denk gelince hata alınması problemini çözmüştür.

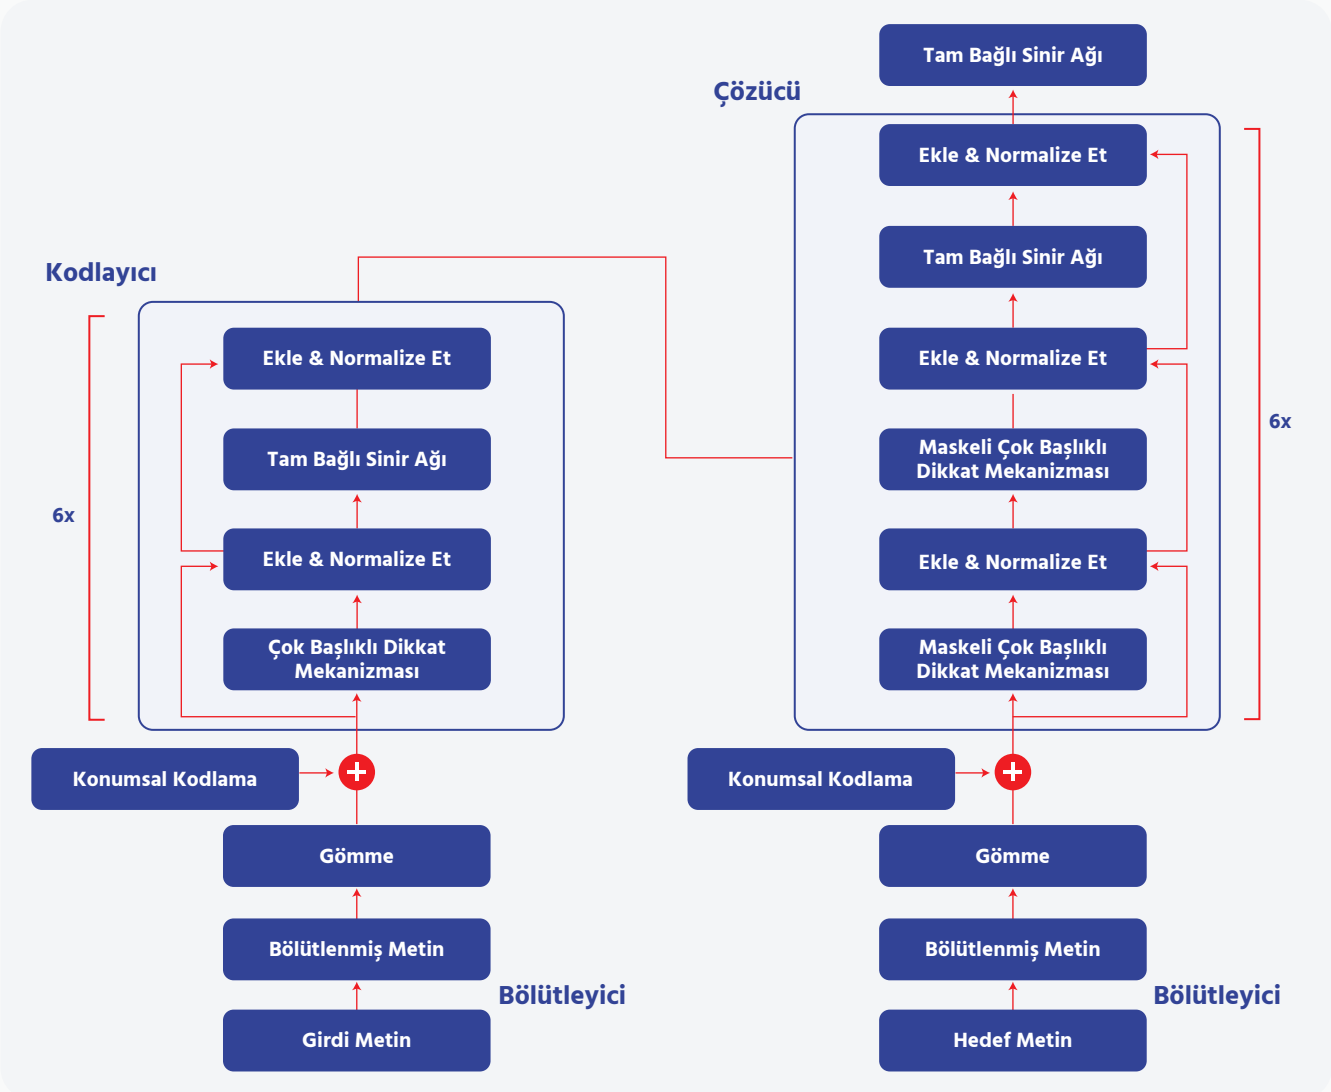
   b. **Kelime Parçacığı Kodlama (Wordpiece Encoding):** Yaklaşımı BPE'ye benzerdir. BPE'den temel farkı, bölütleme işleminde önce metni kelimelere bölüp, potansiyel kelime altı birimlerin metinde ne kadar sıklıkla geçtiğine göre yeni bölüt oluşturma kararını vermesidir. Eğer çok sık geçen kelime altı birim varsa (İngilizcede "the" kelimesi ve "th" kelime altı birimi gibi) kırılım yapılarak ayrı bir bölüt olarak belirlenir. Google tarafından geliştirilmiştir. Bu alanda çok yaygın olarak kullanılmakta olan BERT (Bidirectional Encoder Representations from Transformers) modellerinde kullanılmaktadır.

c. **Cümle Parçacığı Kodlama:** Diğer kodlama yöntemlerinde metin sayısallaştırması aşamasında metnin kelimelere bölünmesi sık kullanılan bir yöntemdir. Fakat bu yöntemler, yapısı gereği cümlelerdeki kelimelerin boşlukla ayrılmadığı, Japonca ve Çince gibi dillerde başarımı düşürmekte veya dile özgün ek işleme gerektirmektedir. Bu kodlama yöntemi doğrudan cümleleri işleyebilme ve boşlukları bir ayraç değil ayrı bir bölüt olarak ele alma açısından BPE'den farklılaşmaktadır.

2. **Kodlayıcı (Encoder):** Bölütleme sonrasında vektörler ile ifade edilmiş metinler, anlamlarının sayısallaşabilmesi adına bir dizi işlemden geçerler. Bu aşamada üretilen vektörler eğitim verilerinden ve eğitim stratejilerinden doğrudan etkilenirler. Bu işlemler sonucu oluşan vektörler, yeni metnin oluşması adına çözücü (decoder) kısmına geçer.

3. **Çözücü (Decoder):** Kodlayıcıdan çıkmış verilerden yeni metinlerin üretilmesi aşamasıdır. Kodlayıcı tarafında olduğu gibi bu aşama da eğitim verilerinin niteliğinden ve eğitim stratejisinden doğrudan etkilenir.

Şekil 1'de transformer mimarisinin görseli sunulmuştur.



Şekil 1. "Transformer" Mimarisi ve Dikkat Mekanizması [2]

Edinim Artırımlı Üretimin Kullanılma Gerekçesi

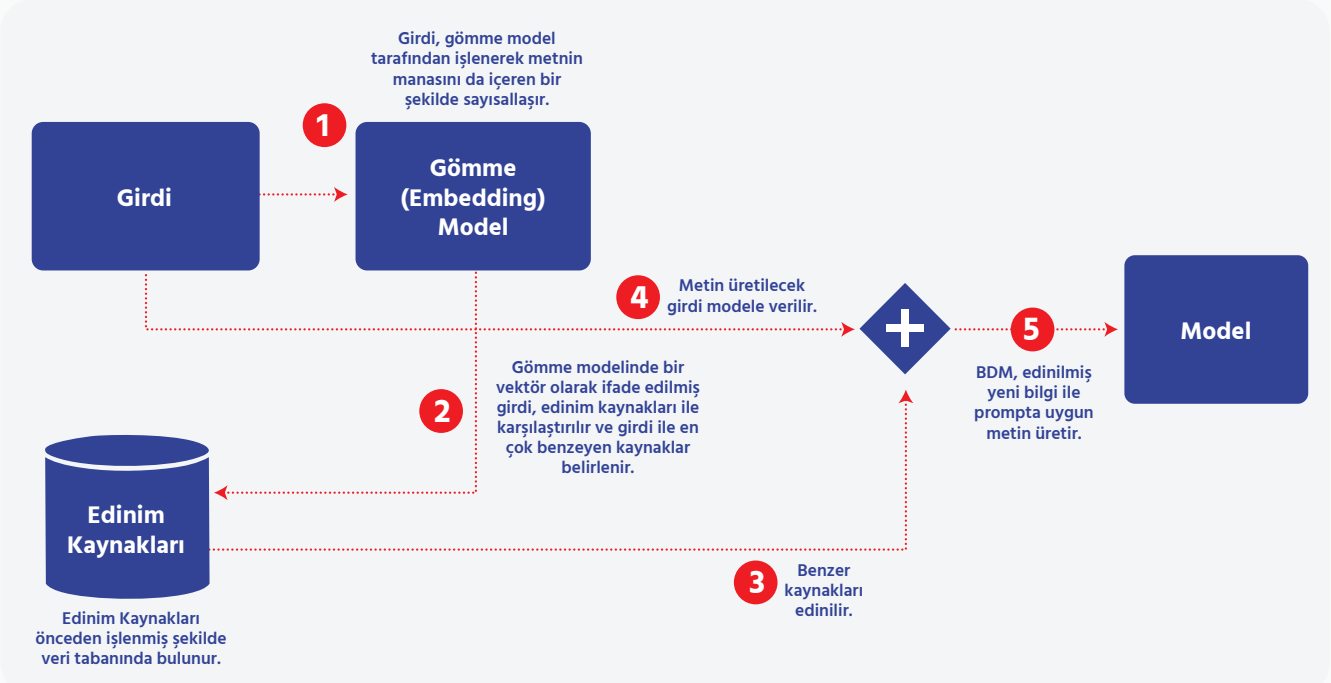
Özünde dili, sırasallık kurgusuyla ele alan transformer mimarisi, eğitim verisinde yer alan sırasallığa meyleder. Dolayısıyla eğitim verisinde yeterli miktarda bulunan veriler hakkında metin üretimi istenen kalitede olabilmek ile birlikte, eğitim verisinde hiç bulunmayan, yeterli miktarda bulunmayan veya istenen bağlamda bulunmayan metinlerin analizinde modeller tek başlarına istenen kalitede çıktı üretememektedirler.

Bu durumun üstesinden gelmek adına çeşitli yöntemler kullanılmaktadır. Yaygın olarak kullanılan yöntemler incelendiğinde modelin eğitiminin sahip olunan veriyle devam ettirilmesi, modelin sahip olduğu sinir ağlarına yeni katmanlar eklenmesi, seçili bazı katmanların yeniden eğitilmesi gibi eğitim gerektiren yöntemlerin yanında ek eğitim gerektirmeyen ve bu yazının temel konusu olan edinim artırılmlı üretim yöntemi de kullanılmaktadır. Eğitim gerektirmemenin yanı sıra, edinim kaynaklarının değiştirilebilmesi, bilginin dinamik olduğu ortamlar da edinim artırımlı üretimin tercih sebepleri arasında yer almaktadır.

Edinim Artırımlı Üretim

Edinimle artırım, modelin eğitim esnasındaki süreçlerini etkilemez, sadece metnin üretildiği aşamayı etkiler. Bir doğal dil modeli içermenin yanı sıra, kendisinden edinimin gerçekleşeceği kaynakların yönetilmesini de içerir. Edinimin gerçekleştirileceği kaynaklar, üretimin öncesinde işlenmelidir.

Edinim artırımlı üretim sistemini anlatan görsel aşağıda verilmiştir. Numaralar gerçekleşme aşamalarını göstermektedir.



Şekil 2. Edinim Artırımlı Üretim Süreci

Edinim Artırımlı Üretim Aşamaları

Üretim aşamalı olarak incelendiğinde süreç temelde şu aşamalardan geçer: kaynaklarda değişiklik olmaması halinde bir defaya mahsus olacak şekilde sorgu öncesinde edinime konu olacak kaynakların işlenmesi, sorgunun sayısallaşması, sayısallaşmış sorgu cümlesi ile, edinim kaynaklarının karşılaştırılacak edinim için uygun kaynak parçalarının belirlenmesi, varsa; edinilen çok sayıda kaynak parçasının alaka durumuna göre yeniden sıralanıp daha alakalı kaynak parçalarının tespit edilmesi ve son olarak girdi ve alakalı kaynak parçalarının modele sunularak modelden cevap alınması. Bu sürecin daha detaylı aktarımı aşağıdaki gibidir;

Edinim Kaynaklarının Hazırlanması

Edinim kaynaklarında bulunan bilginin üretim esnasında edinilebilmesi için sayısallaşması gerekir. Bu sayısallaşma için edinim kaynağına göre çeşitli yöntemler takip edilebilmekle birlikte yaygın süreç, edinim kaynaklarının parçalanması ve her bir parçanın bir gömme modeli ile sayısallaştırılmasıdır. Sayısallaşma sonucunda her bir parçayı ifade eden vektörler elde edilir. Edinim esnasında doğru bilginin modele beslenmesi için parçalamanın yöntemi önemlidir. Yaygın olarak kullanılan parçalama stratejileri aşağıdaki gibidir;

1. **Sabit Uzunlukta Parçalama:** Kaynağın bilgiyi sunuş tarzından bağımsız olarak, her bir kaynağın, boyutu önceden belirlenmiş bir karakter sayısına göre parçalara ayrılmasıdır. Uygulaması basittir fakat dokümanın bilgiyi sunuş tarzını korumakta yetersiz kalabilir.

2. **Cümle/Paragraf Bazında Parçalama:** Metnin dil bilgisi kurallarına yönelik olarak paragraf veya cümle ölçeğinde parçalanmasıdır. Bu bölümlerin, metnin ilk oluşturucusu tarafından bölümlenmesinde yapılan tercihler edinimin başarısını etkiler.

3. **Hiyerarşik Parçalama:** Kaynağın sunduğu bilgiyi, anlamsal veya şekli olarak genelden özele doğru birkaç seviyeden oluşan hiyerarşilere bölecek şekilde parçalamaktır. Bir örnek olarak, ilk seviye, bir kaynağın tamamı için oluşturulan bir özet, ikinci seviye her bir sayfası için oluşturulan özetler gibi oluşturulabilir. Bu yöntemde edinimin kendisi de önce alakalı olan genel bölümlerin tespiti ve sonrasında ilgili genel bölümün alakalı alt parçalarının tespitiyle gerçekleşir.

4. **Anlamsal Parçalama:** Kaynakların kapsadığı farklı anlam kümelerinin, tespit edilmesi ve her bir kümenin ayrı bir parça haline getirilmesidir. Doküman içerisindeki anlam kümelerinin belirlenmesinin manuel olarak yapılması çok zor olabileceği gibi, bu kümelerin gömme modelleri ile belirlenmesi aşamasında her bir anlam kümesinin sınırlarını doğru belirleyebilecek bir model bulmak veya oluşturmak süreci karmaşıklaştırmaktadır.

Bütün bu yöntemlere ek olarak günümüz resimden metin üretme modellerinin ulaşılabilirliğinin artmasıyla dokümandaki görsellerin de işlenebilmesinin kullanımı da yaygınlaşmaktadır [3]. Yazı içeriğinin odağının korunması adına çalışma metin temelli sistemlerce sınırlı tutulmuştur.

Alakalı Bölümlerin Tespiti

Sisteme bir girdi verildiğinde, sistem ilgili girdiyi, kaynakların sayısallaştırılmasında kullanılan gömme modeli ile sayısallaştırır. Sayısallaştırma sonrasında girdinin vektör temsili elde edilir. Bu vektör, edinim kaynaklarının parçalarının vektör temsilleriyle matematiksel olarak karşılaştırılır, en yakın olan parçalar modele sunulmak üzere alakalı olarak tespit edilir. Yaygın gömme modellerinde bu vektör 512, 768 veya 1024 elemanlıdır. Yaygın olarak kullanılan vektör benzerlik tespit yöntemleri aşağıdaki gibidir;

- **Kosinüs Benzerliği:** İki doğru arasındaki kosinüs açısının hesaplanmasıdır. Sonuç -1 ile 1 arasındadır. 1'e yakınlık benzerliği gösterir.
- **Öklid Uzaklığı:** Çok boyutlu uzayda iki nokta arasındaki düz çizginin uzunluğudur. Aradaki mesafenin kısa olması benzerliğin yüksek olduğu anlamına gelir.
- **Nokta Çarpımı:** 2 vektör arasındaki nokta çarpımının hesaplanması ile belirlenir. Nokta çarpımının sonucunun büyük olması benzerliğin yüksek olduğu anlamına gelir.

Yeniden Sıralama (Reranking)

Büyük dil modeline beslenebilecek çok sayıda kaynak var olduğunda, modelin tek seferde işleyebileceği bölüt miktarını belirten bir limit olan "context window (bağlam penceresi)" kısıtlayıcı olmaktadır. Bağlam penceresinin büyüklüğü modelin ilk eğitimi esnasında verilen bir karar olup ilk eğitim sonrasında pencerenin değişmesi için modelin eğitiminin devam ettirilmesi gerekmektedir. Bir model bağlam penceresinden daha fazla bölüt ile işleme yapamamakta, kendisinden bağlam penceresinin tamamı kullanılarak metin üretmesi istenirse, bu durum modelin kendisine verilen metindeki detayları kaçırmasına sebep olmaktadır.

Yeniden sıralayıcı kullanımı bu aşamada devreye girmekte ve edinimi aşamalandırmaktadır. Yeniden sıralayıcının kullanıldığı senaryoda, bir benzerlik modeli ile çok sayıda alakalı parça hızlıca tespit edilebilirken, bu alakalı parçalar arasından en alakalı olanlar, ilk edinimdeki modele göre daha yavaş fakat daha doğru sonuç veren bir yeniden sıralama modeli tarafından yeniden alakalarına göre sıralanmakta ve dil modeline verilecek metnin boyutu azaltılmaktadır.



Modele Sunum

Son aşama olarak, edinim kaynaklarının parçalarından alakalı olduğu ortaya konanlar ve kullanıcının girdisi, BDM'ye sunulur. BDM, cevap üretirken edinim kaynaklarındaki bilgiye göre cevap üretmiş olur. Bu sayede modelin kendisi değiştirilmeden, sadece edinim kaynaklarından alakalı olanların üretime dahil edilmesi sağlanır. Bu yolla modelin kendisi değiştirilmeden çıktısının kalitesi artırılmış olur. Edinim kaynakları çoğunlukla veri tabanı gibi yazılımlarda barındırıldığı için ekleme, çıkarma güncelleme ve erişim yönetimi gibi çeşitli operasyonlar yürütülebilir.

Uygulama Örneği

Python üzerinde basit bir uygulama örneği ile edinim artırımlı üretim tekniğinin büyük dil modellerinin başarısını nasıl artırdığı aşağıda incelenmektedir.

Uygulamayı gerçekleştirebilmek adına teknoloji ve yazılım yığını aşağıdaki gibi belirlenmiştir;

- Ubuntu 22.04.4
- Python 3.10, LlamaIndex [4]
- Ollama üzerinde büyük dil modeli olarak aya35b, 4 bit nicemlenmiş (quantized) [5]
- Gömme modeli olarak BAAI/bge-large-en-v1.5 [6][7]

Sistemin çalışması esnasında video RAM kullanımı 24 GB'ı geçmemiş olup, bu miktar profesyonel olmayan kullanıcılar tarafından da erişilebilir bir miktardır. Farklı modellerin veya soruların kullanımı video RAM kullanımını etkiler.

Edinim artırımlı üretimin gerçekleştirilmesinde kullanılan kod aşağıda verilmiştir;

```
from llama_index.core import VectorStoreIndex, SimpleDirectoryReader, Settings
from llama_index.embeddings.huggingface import HuggingFaceEmbedding
from llama_index.llms.ollama import Ollama

# Edinim kaynaklarının bulunduğu klasörün yolu verilmeli
documents = SimpleDirectoryReader("/home/sedat/Masaüstü/arastirmaDeneme/data").
load_data()
# Sistemde kullanılacak embeddings modeli verilmeli
# https://huggingface.co/spaces/mteb/leaderboard adresinden farklı embedding
modelleri bulunabilir
Settings.embed_model = HuggingFaceEmbedding(model_name="intfloat/multilingual-
e5-large",trust_remote_code=True)
```

```
# Model arkayüzü olan ollama ile haberleşebilmek için modelimizi belirtiyoruz
Settings.llm = Ollama(model="aya:35b", request_timeout=360.0)

# llamaindex kütüphanesinde hazır olan VectorStoreIndex.from_documents
fonksiyonu ile
# edinim kaynakları parçalara ayrılır ve sonrasında ulaşılabilmek adına "index"
KaynakParcalari = VectorStoreIndex.from_documents(documents,show_progress=True)

# Kullanıcı girdi sağlar
query_engine = KaynakParcalari.as_query_engine()
response = query_engine.query("On ikinci kalkınma planınında dijital dönüşüm
ile ilgili hangi politikalar bulunmaktadır? Bu politikaların kendilerini ve
tanımlayıcılarını söyler misin ?")
print(response)
```

Çıktı Üretim Süreci

RAG sisteminin üretim başarısının anlaşılması adına 3 adet soru belirlenmiştir, bu sorular öncesinde doğrudan modele sorulmuş, sonrasında aynı model RAG sistemi ile kullanılmıştır. RAG sistemine veri olarak aşağıdaki dokümanlar verilmiştir;

1. 2024 Yılı Yatırım Programı
2. On İkinci Kalkınma Planı 2024-2028
3. Orta Vadeli Program 2025-2027

Sorular aşağıdaki gibidir;

1. On ikinci kalkınma planında dijital dönüşüm ile ilgili hangi politikalar bulunmaktadır? Bu politikaların kendilerini ve tanımlayıcılarını söyler misin?
2. On ikinci kalkınma planı ne zaman yazılmıştır?
3. On ikinci kalkınma planında yapay zeka ile ilgili ne gibi unsurlar bulunmaktadır? Bu unsurlar hangi maddelerde verilmiştir?



Edinim Artırımsız Cevaplar

Sistemin edinim artırımı kullanılmadığı halinde, sorular doğrudan büyük dil modeline gönderilmektedir. Bu halde beklenti, modelin sadece kendi eğitimi ile alan özgü sorulara cevap veremeyeceğidir. Aşağıdaki örneklerde görüldüğü üzere; model, beklentiye paralel şekilde çeşitli sebeplerce kalitesiz cevaplar vermektedir. Çıktı Değerlendirmesi başlığı altında cevap kaliteleri ayrıca incelenecektir.

Soru

On ikinci kalkınma planında dijital dönüşüm ile ilgili hangi politikalar bulunmaktadır? Bu politikaların kendilerini ve tanımlayıcılarını söyler misin?

Cevap

On ikinci kalkınma planında "Dijital Dönüşüm" politikaları, Türkiye'nin ekonomik, sosyal ve kültürel gelişiminin temelini oluşturuyor. Bu politikalar, teknolojiyi etkin bir şekilde kullanarak ülkenin küresel rekabet gücünü artırmayı ve yaşam standartlarını yükseltmeyi hedefliyor. İşte On ikinci kalkınma planınınında öne çıkan dijital dönüşüm politikaları:

1- "Dijital Ekonomi" politikası:

Bu politika, Türkiye'nin bilgi teknolojilerine dayalı bir ekonomi oluşturarak küresel pazarda rekabetçi bir oyuncu haline gelmesini amaçlamaktadır. Politikanın tanımlayıcıları şunlardır:

a) "Bilgi Teknolojileri ve İletişim Altyapısının Geliştirilmesi": Bu tanımlayıcı, fiber optik ağlar, 5G ve sonraki nesil iletişim teknolojilerinin geliştirilmesine odaklanmaktadır. Hedef, yüksek hızlı, güvenilir ve erişilebilir bir dijital altyapı oluşturmaktır.

b) "Dijital Becerilerin Geliştirilmesi": Bu tanımlayıcı, eğitim sisteminde dijital okuryazarlık ve teknik becerileri geliştirmeyi amaçlamaktadır. Hedef, iş gücüne dijital ekonomi için gerekli becerileri kazandırmaktır.

2- "Akıllı Şehirler" politikası:

Bu politika, şehirlerin teknolojiyi kullanarak daha sürdürülebilir, verimli ve yaşanılabilir hale getirilmesini hedeflemektedir. Politikanın tanımlayıcıları şunlardır:

a) "Akıllı Ulaşım": Bu tanımlayıcı, elektrikli araçlar, otonom ulaşım teknolojileri ve akıllı trafik yönetim sistemleri gibi yenilikçi ulaşım çözümlerini teşvik etmeyi amaçlamaktadır. Hedef, sürdürülebilir ve verimli bir ulaşım ağı oluşturmaktır.

b) "Akıllı Şehir Hizmetleri": Bu tanımlayıcı, e-devlet hizmetleri, akıllı enerji yönetimi ve atık yönetimi gibi vatandaşlara yönelik dijital hizmetlerin geliştirilmesine odaklanmaktadır. Hedef, vatandaşların yaşam kalitesini artırmaktır.

3- "Sanayi 4.0" politikası:

Bu politika, imalat sektörünün dijital dönüşümünü hızlandırarak küresel pazarda rekabetçi bir oyuncu haline gelmesini amaçlamaktadır. Politikanın tanımlayıcıları şunlardır:

a) "Üretim Süreçlerinin Dijitalleştirilmesi": Bu tanımlayıcı, endüstriyel internet teknolojileri, büyük veri analitiği ve yapay zekanın üretim süreçlerine entegrasyonuna odaklanmaktadır. Hedef, esnek, verimli ve akıllı üretim süreçleri oluşturmaktır.

b) "Endüstriyel Otomasyon": Bu tanımlayıcı, robotik, makine öğrenmesi ve yapay zeka teknolojilerinin kullanımı teşvik edilmektedir. Hedef, üretim süreçlerinin otomasyonu ve verimliliğin artırılmasıdır.

4- "E-ticaret" politikası:

Bu politika, dijital platformların kullanımını teşvik ederek ekonominin büyümesine katkıda bulunmayı amaçlamaktadır. Politikanın tanımlayıcıları şunlardır:

a) "E-ticaret Altyapısının Geliştirilmesi": Bu tanımlayıcı, güvenli ve erişilebilir bir e-ticaret ekosistemi oluşturmaya odaklanmaktadır. Hedef, işletmelerin çevrimiçi pazara katılımını teşvik etmektir.

b) "Dijital Ödeme Sistemlerinin Yaygınlaştırılması": Bu tanımlayıcı, kredi kartları, mobil ödeme yöntemleri ve blockchain teknolojileri gibi alternatif ödeme sistemlerinin kullanımını teşvik etmektedir. Hedef, e-ticareti destekleyen güvenli ve verimli ödeme altyapısının geliştirilmesidir.

On ikinci kalkınma planı, dijital dönüşüm politikalarını kapsamlı bir şekilde ele alarak Türkiye'yi küresel dijital ekonomiye entegre etmeyi hedeflemektedir. Bu politikaların başarılı bir şekilde uygulanması, ülkenin ekonomik büyümesine, sosyal gelişimine ve vatandaşların yaşam standartlarına olumlu katkılar sağlayacaktır.

Soru

On ikinci kalkınma planı ne zaman yazılmıştır?

Cevap

On İkinci Beş Yıllık Kalkınma Planı, 2017-2022 yılları arasını kapsayacak şekilde hazırlanmış ve 2017 yılında yayınlanmıştır.

Soru

On ikinci kalkınma planında yapay zeka ile ilgili ne gibi unsurlar bulunmaktadır? Bu unsurlar hangi maddelerde verilmiştir?

Cevap

Türkiye'nin On İkinci Beş Yıllık Kalkınmada AI koordine edici rolüne yönelik olarak; 20.1.3. Yapay Zeka (YZ) ve Büyük Veri Hattında belirtilen hedeflere ulaşmak amacıyla YZ ekosistemi geliştirilmesinde, Ar-Ge, pilot uygulama ve kapasite oluşturmaya yönelik çalışmalara öncelik verilmesi,

20.3.1. Akıllı Ulaşım Sistemleri ve Lojistikte, gelişmiş teknolojilerin (YZ, IoT, büyük veri analitiği gibi) kullanımının artırılması,

20.4.1. Sağlık hizmetlerinin akıllı teknolojiler (YZ, VR/AR, IoT, blockchain) ile geliştirilmesi,

20.5.2. Tarımsal verimliliğin ve kalitenin YZ, IoT, uzaktan algılama ve robotik teknolojileri kullanılarak artırılması,

20.6.1. Madencilik sektöründe, kazma-sınıflandırma algoritmalarıyla iş güvenliğinin sağlanması, madenlerin optimizasyonu, YZ tabanlı analizlerle verimliliğin artırılması,

20.7.1. İmalat Sanayii'nde YZ tabanlı zeka merkezlerinin oluşturulması,

20.7.3. Finansal hizmetlerde YZ ve blockchain teknolojilerinin kullanımının artırılması,

20.8.2. Eğitimde VR/AR ve YZ teknolojilerinin kullanımıyla öğrendiğin deneyimlendirerek öğretme yönteminin yaygınlaştırılması,

21.3.1. Kamu yönetimine YZ teknolojilerinin entegre edilmesi,

21.6.1. Güvenlik ve siber güvenlik alanlarında YZ teknolojilerinin geliştirilmesi ve veri güvenliği için blockchain teknolojisinin kullanımı,

21.7.1. Medyada YZ teknolojilerinin kullanımının artırılması,

21.8.1. Kültürel ve sanatsal faaliyetlerde VR/AR, YZ, blockchain ve diğer ileri teknolojilerin kullanılması teşvik edilir.

Edinim Artırımlı Cevaplar

Sorunun dil modelinden önce çeşitli edinim kaynaklarındaki veriler ile zenginleştirilmesi sonucunda model doğrudan eğitim verisinde yer almayan konularda daha kaliteli cevaplar verebilmektedir. Cevap kalitesi Çıktı Değerlendirmesi başlığında daha detaylı olarak ele alınacaktır.

Soru

On ikinci kalkınma planında dijital dönüşüm ile ilgili hangi politikalar bulunmaktadır? Bu politikaların kendilerini ve tanımlayıcılarını söyler misin?

Cevap

On İkinci Kalkınma Planı'nda dijital dönüşümle ilgili aşağıdaki politikalar bulunmaktadır:

964.4: Dijital devlet mimarisiyle uyumlu kurumsal dijital dönüşüm olgunluk modeli geliştirilecektir.

964.5: Kamu bilgi teknolojileri denetim süreçlerinde iç kontrol ve iç denetim etkinleştirilecektir.

964.6: İstatistiki veri altyapısını iyileştirmek için temel dijital devlet göstergeleri belirlenerek alana özgü ulusal endeks oluşturulacaktır.

964.7: Dijital teknolojilerin kamu yönetimine etkilerini araştırmak ve alandaki gelişmelere yönelik stratejik karar alma kapasitesini artırmak amacıyla araştırma ve yenilik programı başlatılacaktır.

965: Kamu bilişim personeli istihdamı ihtiyaçlara göre nitelik ve nicelik olarak iyileştirilecektir. Bu kapsamda, kamu bilişim personelinin rol ve sorumluluklarını belirleyen ve yetkinliklerini ortaya koyan bir "Kamu Bilişim Yeterlik Çerçevesi" geliştirilecektir.

Bu politikaların tanımlayıcıları veya kodları, metinde verilen sayısal değerlerdir. Örneğin, 964.4, 964.5 vb.

Soru

On ikinci kalkınma planı ne zaman yazılmıştır?

Cevap

31.10.2023

Soru

On ikinci kalkınma planında yapay zeka ile ilgili ne gibi unsurlar bulunmaktadır? Bu unsurlar hangi maddelerde verilmiştir?

Cevap

On İkinci Kalkınama Planı'nda yapay zeka ile ilgili aşağıdaki unsurlar bulunmaktadır:

591. Yapay zekâ alanındaki temel teknolojilerin geliştirilmesi desteklenecek ve kullanımı yaygınlaştırılacaktır.

591.1. Kamu, üniversite ve özel sektör arasındaki işbirlikleri güçlendirilecektir.

591.2. Uluslararası işbirlikleri artırılacak ve yapay zeka teknolojilerinin doğurduğu ihtiyaçlar için gerekli yasal düzenlemeler yapılacaktır.

Bu unsurlar 591 ve alt maddeleri olan 591.1, 591.2 ve 591.3 maddelerinde yer almaktadır.

Çıktı Değerlendirmesi

- 1. soruya verilen cevaplar karşılaştırıldığında, her iki yöntem de Türkçe içerik üretmekte başarılı olmakla birlikte edinim artırımsız üretimde verilen cevaplar kalkınma planı ile neredeyse tamamen alakasızdır. Edinim artırımlı üretim alakalı dokümanı doğru tespit etmiştir. Lakin edinim artırımlı üretim yönteminin de geçerli sayılabilecek tüm cevapları vermediği de değerlendirilmiştir. Daha doğru bir cevap, 964 ile başlayan tanımlayıcılara sahip diğer politikalara da yer verebilirdi.
- 2. soruya verilen cevaplar karşılaştırıldığında, edinim artırımsız cevabın yanlış, artırımlı cevabın doğru olduğu görülmektedir.
- 3. soruya verilen cevaplar karşılaştırıldığında, edinim artırımlı üretim sisteminin dokümanı doğru tespit ettiği ve verdiği cevabın kısmen doğru olduğu değerlendirilmiştir. Edinim artırımlı üretim sistemi, 591 ile başlayan tanımlayıcıları doğru olarak tespit etmiş fakat yapay zeka ile ilgili olarak kabul edilebilecek 688.6, 718.2 gibi çeşitli politikaları tespit edememiştir. Ayrıca cevabında 591, 591.1, 591.2 tanımlayıcılı unsurları madde yazılarıyla beraber vermiş, 591.3'ün metnini atlamıştır.



Sonuç ve Öneriler

Edinim artırımlı üretim, temelde edinim ve üretim aşamalarından meydana gelen ve doğal dil işleme alanlarında son dönemler de daha da ivme kazanmış ve gelecekte de daha fazla değer kazanması öngörülen bir tekniktir. Üretim modelinin sabit tutulup, edinim kaynaklarının basitçe değiştirilebilmesi sürekli yeni bilgilerin üretildiği ortamlarda dahi ek bir eğitim maliyeti olmadan güncel bilginin dikkate alınarak üretim gerçekleştirilmesini mümkün kılar.

Yazımızda giriş seviyesinde doğal dil modelleri ile üretime ve sonrasında yine giriş seviyesindeki bilgiler ile edinim artırımlı üretime değindik. Edinimsiz artırımlı üretimin, Türkçe cümle kurma açısından başarılı sonuçları olabilmekle birlikte, cevaplarda içerdiği bilgilerin çeşitli fazlaca yanlış olduğu fakat edinim artırımlı üretimin başarılı sonuçlar üretebildiğini görmüş olduk. Ayrıca uygun konfigürasyonların seçilmesi halinde bu sistemin son kullanıcı donanım bileşenleri ile de sağlanabileceğini görmüş olduk. Buna rağmen önemli bir unsur, kullanılan teknikten ve modelden bağımsız olarak dil modellerinin temelde istatistik temelli modeller olması ve dolayısıyla ürettikleri bilginin gözden geçirilmesi gerekliliğidir. Günümüz büyük dil modellerinin hiçbiri her daim hakikati ortaya koyamamaktadır. Dolayısıyla konuyla alakalı ek bilgiye sahip olsalar da ürettikleri metin her daim gerçeği yansıtmayabilir.

Kaynakça

1. P. Lewis vd., “Retrieval-Augmented Generation for Knowledge-Intensive NLP tasks,” arXiv (Cornell University), Ocak, 2020, doi: 10.48550/arxiv.2005.11401

2. A. Vaswani vd., “Attention is all you need,” arXiv (Cornell University), Ocak, 2017, doi: 10.48550/arxiv.1706.03762.

3. W. Chen, H. Hu, X. Chen, P. Verga, ve W. W. Cohen, “MuRAG: Multimodal Retrieval-Augmented Generator for Open Question Answering over Images and Text,” arXiv.org, Eylül, 06, 2022. https://arxiv.org/abs/2210.02928 (Erişim Zamanı: Mart, 15, 2024).

4. “LlamaIndex - Data Framework for LLM Applications,” llamaindex.ai, URL: https://www.llamaindex.ai/ (Erişim Zamanı: Mart, 15, 2024).

5. V. Aryabumi vd., “Aya 23: Open Weight Releases to Further Multilingual Progress”, 2024, arXiv. doi: 10.48550/ARXIV.2405.15032.

6. “BAAI/bge-large-en-v1.5 · Hugging Face,” huggingface.co, URL: https://huggingface.co/BAAI/bge-large-en-v1.5 (Erişim Zamanı: Mart, 15, 2024).

7. S. Xiao, Z. Liu, P. Zhang, N. Muennighoff, D. Lian, ve J.-Y. Nie, “C-Pack: Packed Resources For General Chinese Embeddings”, 2023, arXiv. doi: 10.48550/ARXIV.2309.07597.

8. “Retrieval Augmented Generation market size, share & trends analysis Report by function, by application, by deployment (Cloud, on-premises), by end-use (Healthcare, Education), by region, and segment Forecasts, 2024 - 2030.” https://www.grandviewresearch.com/industry-analysis/retrieval-augmented-generation-rag-market-report (Erişim Zamanı: Mart, 15, 2024).



T.C. SANAYİ VE
TEKNOLOJİ BAKANLIĞI

#MİLLİ TEKNOLOJİ HAMLESİ

TÜBİTAK

İşçi Blokları Mahallesi Muhsin Yazıcıoğlu Caddesi No:51/C 06530 Çankaya/ANKARA

+90 (312) 289 92 22 - yte.bilgi@tubitak.gov.tr

TÜBİTAK - BİLGEM Yazılım Teknolojileri Araştırma Enstitüsü (YTE)