DOI: 10.53478/TUBA.978-625-8352-48-1.ch23

AKILLI SAĞLIK SİSTEMİ VE YAPAY ZEKÂ

Dr. Mehmet Haklıdır
TÜBİTAK Bilişim ve Bilgi Güvenliği İleri Teknolojiler Araştırma Merkezi

Dr. Sinem Nalbantoğlu
TÜBİTAK Marmara Araştırma Merkezi

Doç. Dr. Abdullah Karadağ
TÜBİTAK Marmara Araştırma Merkezi

Özet

Son yarım asırda moleküler biyolojideki gelişmeler sonucu yüksek hacimli modern teknolojiler yardımı ile canlı bir organizmadan genomik, transkriptomik, proteomik ve metabolomik seviyelerde yüksek miktarlarda büyük veriler (BigData) üretilmiştir. İstatistik bilimi ve bilişim teknolojilerinde de benzer hızda gelişmeler olmasına rağmen, biyoinformatik yöntemlerle büyük verilerin analizi ile hastalıkların altındaki mekanizmaların ortaya konulması ve etkin tedavi sistemlerinin geliştirilmesinde yeterli oranda gelişme kaydedilememiştir. Yakın bir gelecekte, özellikle gelişmiş ülkelerde sağlık hizmetlerinin tamamen akıllı sistemler aracılığıyla verilmesi öngörülmektedir. Bu dönüşümün, sistem biyolojisinin merkezinde olduğu büyük veri, yapay zekâ, entegre çoklu-omik ve kişiye-özgü tıp sacayaklarından oluşan bir yapı ile devreye gireceği öngörülmektedir. Bu yapının elde edilmesi başlangıçta maliyetli olsa da zamanla kişiye özel uygulamalar sayesinde daha ekonomik hale gelecektir. Çünkü insanların hem daha sağlıklı yaşaması mümkün olacak, hem muhtemel riskler önceden belirlenerek daha etkin ve özgül koruyucu önlemler alınabilecek, hem de oluşan patolojiler hastanın biyolojik altyapısına uygun tedavi sistemleri ile daha ekonomik olarak kontrol altına alınabilecektir. Bu bölümün amacı hem dikkatleri önümüzdeki yıllarda daha çok tartışılacak akıllı sağlık sisteminin muhtemel kurgularına çekmek, hem de modelin dinamiklerini ve yapılması gerekenleri kısaca özetlemektir. Bu sistemin temel sacayaklarından olmasını beklediğimiz ve son yıllarda hızla gelişmeye başlayan yapay zekâ bilimindeki gelişmeler ve akıllı sağlık sistemine uyarlamaları sistem biyolojisi merceği ile gözden geçirilecektir.

Anahtar Kelimeler

Akıllı sağlık sistemi, Yapay zeka, Büyük veri, Biyoinformatik, Kişiye-özgü tıp

DOI: 10.53478/TUBA.978-625-8352-48-1.ch23

SMART HEALTHCARE SYSTEM AND ARTIFICIAL INTELLIGENCE

Abstract

In the last half century, as a result of breakthroughs in molecular biology, incredible amounts of big data have been produced from a living organism at the genomic, transcriptomic, proteomic and metabolomic levels with the help of high-volume modern technologies. Despite the similar rapid developments in statistical science and information technologies, sufficient progress has not been made in revealing the mechanisms underlying diseases and developing effective treatment systems by analyzing big data with bioinformatic methods. In the near future, it is expected that healthcare services will completely transform into intelligent systems. It is envisaged that this transformation will come into play with a structure consisting of big data, artificial intelligence, integrative multiomics and P-medicine, in which systems biology is at the center. Obtaining this structure, although initially costly, will become more economical over time due to individualized applications. Because it will be possible for people to live healthier, possible risks can be determined in advance, and more effective preventive measures can be taken, and the resulting pathologies can be controlled more economically with treatment systems suitable for the patient's biological infrastructure. With this study, we aim to draw attention to the possible constructions of the smart health system, which we will talk about more in the coming years, and to open a discussion about the dynamics and needs of the model. We will review the developments in artificial intelligence, which we expect to be one of the basic pillars of this system and which has developed rapidly in recent years, and their adaptations to the smart health system, with the lens of systems biology.

Keywords

Smart healthcare system, Artificial intelligence, Big data, Bioinformatics.

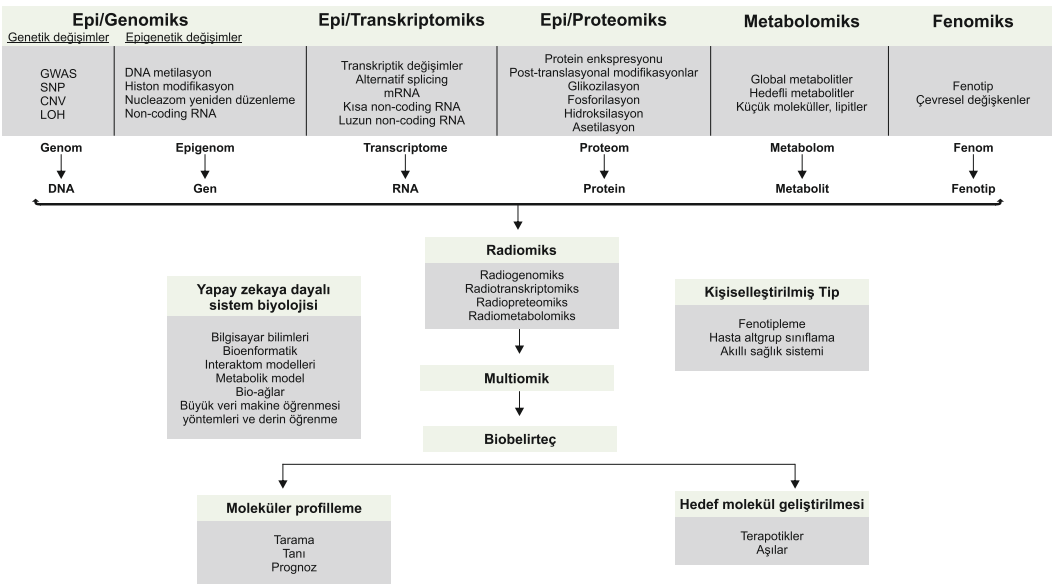
GİRİŞ

Son 40-50 yılda tıp, yaşam bilimleri, bilişim bilimleri ve nanoteknoloji, vb. birçok alanda baş döndürücü gelişmeler yaşanmıştır. DNA sarmalının Watson ve Crick tarafından keşfedilmesinin üzerinden tam yarım asır sonra 2003 yılında insan genom projesi (Human Genome Project–HGP) başarıyla tamamlanmış, hastalıkların erken tanı ve tedavisi ile hastalıkların gelişim ve ilerlemesinde rol oynayan hücresel ve moleküler mekanizmaların tam olarak anlaşılması noktasında küresel ölçekte yankı uyandırmıştır (Collins vd., 2003). Bu büyük buluşa dayalı olarak birçok hastalığın moleküler temeli ortaya konulmuştur ve hastalıkların kişiye-özgü (P-medicine) bir yaklaşımla ele alınmasının gerekliliği ortaya çıkmıştır (Goyal, 2018; Kasztura vd., 2019). Bu doğrultuda yapılan çalışmalar ile uygun tedavilerin belirlenebilmesi için biyobelirteç ve moleküler profilleme tabanlı genetik testlere dayalı sistemler kullanılmıştır. Birçok çalışma ile özgül bir hastalık için risk belirlenmesi, ona göre koruyucu önlem alınması ve gerektiğinde etkin tedavilerin uygulanması mümkün olabilmiştir (Prasad, 2016; Xiping Zhang vd., 2019). Daha sonra, bu etkin uygulamaların hastaların ancak çok küçük bir kısmında etkili olabildiği tespit edilebilmiştir (Meric-Bernstam vd., 2015; Xiping Zhang vd., 2019). Kişiye-özgü tıp yaklaşımından daha çok hastanın faydalanabilmesi için sadece genomik değişimlerin değil, aynı zamanda post-genom değişimlerinin de ortaya konulmasının gerekliliği ortaya çıkmıştır. Ancak, son yıllarda genetik materyali oluşturan DNA sonrası oluşumlar olan RNA, protein ve onların nükleotit veya amino asit dizilerinde değişiklik yapmadan regülasyonunda rol oynayan Epi-(genetik, transkriptomik, proteomik) yapılarındaki değişimlerin önemi fark edilmeye başlanmıştır (Hamamoto vd., 2020).

James Watson tarafından 1965 yılında basılan "The Molecular Biology of the Gene" çalışmasında moleküler biyolojinin merkezi dogması DNA-RNA-Protein olarak tasvir edilmiş – ki biz buna daha sonra "Metabolit" kavramını da ekledik – ve ardından 1980-1990'larda gelişmiş moleküler biyoloji metotları uygulanarak yapılan çalışmalar ile aralarında kompleks biyolojik ilişkiler olduğu anlaşılmaya başlanmıştır (Watson, 1970). 21. yüzyılın sistem biyoloji yaklaşımları insan genleri, transkriptleri, proteinleri, küçük molekül ve metabolitleri ile bu yapıtaşları arasındaki biyokimyasal yolaklar boyunca ilerleyen muazzam etkileşim ve/veya sinerjistik ağ oluşturma ilişkilerinin anlaşılmasına atfedilmiştir. Bu doğrultuda, tek gen, tek transkript, tek protein, tek metabolit gösteriminin yerini hücre içi ve hücreler arası genler, RNAlar, proteinler, ya da metabolitler boyunca oluşan çoklu etkileşim ve ağ sistemleri almaya başlamıştır. Mendel kalıtımındaki tek genli hastalık oluşumu konsepti; fenotipik, allelik heterojen, kronik kompleks, çevresel etkenlerin de birliğinde çok molekül etkileşimli multifaktöriyel hastalık patogenezi portresine yerini bırakmıştır. Yüksek genomik çeşitlilik, moleküler etkileşim ve heterojenitenin meydana getirdiği bu karmaşık patofizyolojik oluşumlar kanser, diyabet, kardiyovasküler, nörolojik, vb. çoğu kronik kompleks hastalığın zeminini oluşturmaktadır. Hastalığa özgü potansiyel biyobelirteçler ve bunların rol aldığı yolaklar ve sinyal ağları da ortaya çıkartılarak moleküler görünümlerin oluşturulması ve bu profili hedefleyen, önleyici (preventif) ve/veya tedavi edici (küratif) potansiyeli olan terapötik sistemlerin geliştirilmesi üzerine oldukça geniş alanda çalışmalar yapılmaktadır (Nalbantoglu & Karadag, 2019, 2021; Sonis & Villa, 2019). Bu noktada yüksek işlem hacimli yeni nesil global ve hedefli spektrometrik tarama, profilleme ve dizileme teknolojileri ciddi miktarda kritik önemi olan ham veri ortaya çıkarmaktadır. Bu ham verinin işlenebilmesi, anlamlı veriye dönüştürülmesi ve biyolojik bağlantılarının gösterilebilir

olması için ileri düzeyde veri analiz teknolojileri önemli derecede gereklidir (Hood, 2013; Subramanian vd., 2020).

Prediktif, diagnostik, prognostik, terapötik biyobelirteçlerin keşfedilmesi, çoklu biyobelirteç panellerinin oluşturulması ve kişiye-özgü tıp kapsamında klinik geçişlerinin tamamlanması oldukça kritiktir. Sistem biyolojisi; genler, transkriptler, proteinler ve metabolitler gibi potansiyel biyobelirteç moleküllerin ortaya çıkarılmasını ve fizyolojik ve patolojik süreçlerin ardındaki mekanizmalarının aydınlatılmasını hedeflemektedir. Sistem biyolojisi hipotez oluşturan yaklaşım iken klasik biyoloji hipotez süren yaklaşımdır ve her ikisi de biyolojik sistemlerin yüksek işlem hacimli analizlerinin gerçekleştirilmesinde birlikte rol oynamaktadır. Sistem biyolojisi ve omiks teknolojileri bütünleşik konsept altında hücre popülasyonları, doku, organ ve tüm organizmanın moleküler seviyede ileri biyoinformatik bilgisayar algoritmaları eşliğinde analiz edilebilirliğini mümkün kılmaktadır (Şekil 23.1). Omik kelime anlamı olarak Yunanca tam, bütün anlamına gelen 'ome' ekinden türemiştir ve bu ekin gen, protein, transkript, metabolit gibi hücresel molekül terimlerine eklenmesiyle genom, proteom, transktiptom, metabolom/lipidom gibi omik teknolojilerinin adlandırılması gerçekleşmiştir (Hood, 2013; Subramanian vd., 2020). Gen ekspresyonu, protein ya da metabolit içeren omik çalışmalarından elde edilen yüksek işlem hacimli veri üzerinde gerçekleştirilen sistem biyolojisi analizi; hastalık özgül profilleme, alt gruplarına göre sınıflandırma, tedavi monitorizasyonu ve terapötik hedef belirlenmesi gibi alanlarda başarıyla uygulanmıştır. Bu biyolojik yapılar birbirleriyle bağlantılıdır ve farklı tipleri birleştirilerek analiz modeline bağlı olarak çoklu-omik analizi gerçekleştirilir.



Şekil 23.1. *Sağlık ve kişiye-özgü tıp alanında uygulanmakta olan büyük omiks veri analizinde yapay zekâ algoritmaları dayalı sistem biyolojisi şeması.*

Yapay zekâ tabanlı sistem biyolojisi yaklaşımları; son derece yüksek genomik, klinik ve biyoinformatik heterojenite içeren kanser sistem biyolojisi omik ve çoklu-omik analizlerinde yüksek çözüm gücü sunmaktadır. Özellikle "kanser metabolik yeniden programlanma mekanizması" üzerine son on yılda çığ gibi büyüyen yapay zekâya dayalı sistem biyolojisi veri

analizleri klinik translasyonu potansiyel biyobelirteç gruplarının belirlenmesi ve immünoterapi gibi umut vaat eden yeni tedavi stratejilerinin geliştirilmesinin önünü açmıştır (Chakraborty vd., 2018; Subramanian vd., 2020).

Akıllı sağlık sistemi mutlak bir gereklilik olan insan biyolojik haritasının tam olarak oluşturulabilmesi için odaklı santral dogmayı merkeze alacak bir yaklaşım ortaya koymak gerekmektedir. Çoklu-omik, DNA odaklı Epi/Genomik, RNA odaklı Epi/Transkritomik, protein odaklı Epi/Proteomik, metabolomik, lipidomik, interaktomik, nutrigenomik, farmakogenomik, eksposomik, vb. birçok etkeni bir arada analiz etmeyi gerektirir (Nalbantoglu & Karadag, 2019, 2021). Epi- ön eki ile yapılan tanımlamalar ilgili birimin dizisinde (nükleotit veya aminoasid) değişiklik yapmadan on/off olmasını düzenleyen unsurları kapsar. Öncelikle standart bir referans olarak DNA, RNA, protein ve metabolit seviyelerinde normal insanın – ki bize göre böyle bir tanım yapılamaz ama bu başka bir çalışmanın konusudur – biyolojik haritasının sistem biyolojisi kurallarına göre oluşturulması ve daha sonra da bunun her bir hastalık için ayrı ayrı yapılması gerekir.

Akıllı sağlık sistemi için ilk sacayak kişi ve etkileşimde olduğu çevreden kaynaklanan biyolojik haritayı entegre çoklu-omik analizleri ile oluşturmaktır. Bir önceki bölümde değindiğimiz gibi yüksek hacimli teknolojilerin yardımı ile bu verilerin üretilmesinde önemli bir mesafe alınmış olmasına rağmen bu verilerin (BigData) analizi konusunda aynı hızda ilerleme sağlanamamıştır. Biyoinformatik bilimindeki gelişmeler ile analiz konusunda önemli ilerlemeler sağlanmış olsa da gerek bilgisayarların işlem gücü gerekse bu verilerin entegre edilmesinde teknik birçok sorun halen aşılamamıştır. Öncelikle elde edilen verilerin birbirleriyle entegre edilebilecekleri formatlarda üretimi sağlanmalıdır. Her bir veri tipindeki bir değişikliğin resmin tamamında (biyolojik network) nasıl bir düzenlemeye yol açtığını işin uzmanı olmayan ilgili paydaşların anlayabileceği bir dile dönüştürmek gerekir. Bu işi yapabilecek hesaplamalı sistem ve algoritmaların geliştirilmesi gerekir. Bunun çok uzak olmayan bir gelecekte başarılacağını öngörebiliriz ki bizler de dâhil birçok bilim insanı bu konuda büyük bir çaba sarf etmektedir. Bu süreçlerde yapay zekâ ve onun unsurlarından olan makine dili ve derin öğrenme son dönemlerde ön plana çıkmaya başlamıştır. Yüksek hacimli verilerin analizinde yapay zekâ gittikçe artan oranlarda daha çok değerlendirilmeye başlanmaktadır.

Akıllı sağlık sistemi sürecinde çocuk sahibi olmak isteyen çiftlerin genetik yapılarının ortaya konulması, bebek sahibi olma planlamaları, fetüs gelişimi safhasında oluşabilecek komplikasyonların takip edilmesi, yeni doğan bebeklerde doğrudan -omik anomalilerin taranması, kanser, diyabet, kardiyovasküler hastalıklar, vb. erken tanı konulmasının hayati önemde olduğu çeşitli hastalıklar için risk gruplarının taranarak erken teşhis edilmeleri, genetik yatkınlıkların tespit edilerek kişiye özgü risklerin belirlenmesi ve buna göre koruyucu önlemlerin alınması, enfeksiyon hastalıklarının önlenmesi, teşhisi ve tedavisi, toplumda yaşlılık ile sıklığı artan hastalıkların (Kanser, Alzheimer, Demans, vb.) daha hızlı bir şekilde tespit ve tedavi edilmesi için omik verilerinin bilinmesi ilk ve en önemli adım olacaktır. Bütün bu önleyici tıp ve bireye özgü tedavi yaklaşımlarının bireyin ömrünü uzatacağı ve daha sağlıklı yaşamasını sağlayacağı öngörülmekle birlikte sağlık sistemi üzerindeki ekonomik maliyeti de azaltacaktır.

Yapay zekâ

Gelişen teknoloji ve işlemci gücüyle akıllı sistemlerin kullanımının hızla arttığı günümüzde yapay zekâ telekomünikasyondan havacılığa, tıptan savunma sektörüne kadar pek çok alanda yaygın olarak kullanılmaktadır. 2030 yılına kadar yapay zekânın, küresel ekonomiye 15.7 trilyon dolar katkıda bulunacağı ve ülke ekonomilerini ortalama %26 oranında büyüteceği beklenmektedir

(Rao & Verweij, 2017). Gelişmiş ülkeler, bu muazzam pazarda paylarını muhafaza etmek ve daha da genişletebilmek için üniversiteler, araştırma merkezleri, teknoloji lideri şirketler ve girişimler aracılığıyla yapay zekâ teknolojileri konusunda çalışmalar yapmaktadır. Peki, nedir bu yapay zekâ?

En genel tanımıyla, yapay zekâ, bir bilgisayarın veya bilgisayar kontrolündeki bir robotun çeşitli faaliyetleri zeki canlılara benzer şekilde yerine getirme kabiliyetidir. Diğer bir tanımlama ile insanın muhakeme, karar verme, ses tanıma, lisan anlama, görsel algı, vb. zekâ gerektiren süreçlerinin çeşitli teoriler, algoritmalar, hesaplamalar ve görevler aracılığı ile yapılan işlemlerini içerir. Yapay zekâ 3 alt başlıkta incelenir (Russell & Norvig, 2002):

1. Dar Kapsamlı Yapay Zekâ (Artificial Narrow Intelligence)
2. Genel Yapay Zekâ – İnsan Düzeyi Yapay Zekâ (Artificial General Intelligence)
3. Süper Yapay Zekâ – İnsan Ötesi Yapay Zekâ (Artificial Super Intelligence)

Yaklaşık 70 yıl önce yapay zekânın vizyonu, insan gibi düşünebilen, öğrenebilen ve akıl yürüten makineler inşa etmekti. Araştırmacılar, insanın genel bilişsel yeteneklerine yakın bir yere ulaşamadıklarında, odak noktalarını çok özel, dar 'zekâ' problemlerini çözmeye yöneltti ve bugüne kadar yapay zekâ neredeyse tamamen bu şekilde uygulandı. İlk yapay zekâ sistemleri, "sorunu bul-çöz-çözümü kodla-uygula" yöntemiyle geliştirilmişti. Bu sistemler geleneksel programlamanın kullanıldığı ve çoğunluğu kural tabanlı yaklaşımların yer aldığı, emek yoğun sistemlerdi. Uygulama alanları ve gelişimleri kısıtlıydı. Eski usul bu yaklaşıma GOFAI (Good Old-Fashioned AI), yani "Güzel, Nostaljik Yapay Zekâ" dendi ve bu dönem "Birinci Dalga" ismi verilerek geride bırakıldı (Şekil 23.2).

Yapay zekâ araştırmacıları, birinci dalga yapay zekâ sistemlerin gelişimlerinin kısıtlı olduğunu fark ettikten sonra, tekrar insan gibi düşünen sistemlere yöneldiler ve insanların nöron yapısını temel alarak yapay sinir ağı yaklaşımını geliştirdiler. Yapay sinir ağı algoritmaları insandaki öğrenme işleyişinden hareketle geliştirildi. Biyolojik sinir sisteminde bulunan nöronların birbirleri ile ilişki kurması gibi yapay sinir ağı sistemlerinde de nöron şeklinde tanımlanan yapılar birbirleri ile bağlantılı olacak şekilde modellendiler (Öztemel, 2003). Buradaki amaç, insanda olduğu gibi yapay zekâya da öğrenme, hafızaya alma ve veriler arasındaki ilişkiyi ortaya çıkarma gibi yeteneklerin kazandırılmasıydı. Bu çalışmalarla başlayan ve özellikle, 2010'lu yıllarda teknoloji ve işlemci gücünde gerçekleşen gelişmelerle çok katmanlı yapay sinir ağlarının geliştirilmesine izin veren derin öğrenme yaklaşımıyla hızlanan bu döneme "ikinci dalga" denilmektedir.

Başlangıçta insan gibi düşünen sistemler olarak hayal edilip heyecan yaratan Yapay Zekâ, 1980'lerde genel yapay zekâya gitmenin güç olduğu fark edilip istatiksel öğrenmeyi esas alan yaklaşımların önemli roller almaya başlaması ile yerini insanların aklına gelen terim olarak "makine öğrenmesi" ne bıraktı. Aynı şekilde derin öğrenme ile elde edilen muazzam başarılar 2010'lu yıllardan itibaren yapay zekâ denilince akla derin öğrenmeyi getirdi.



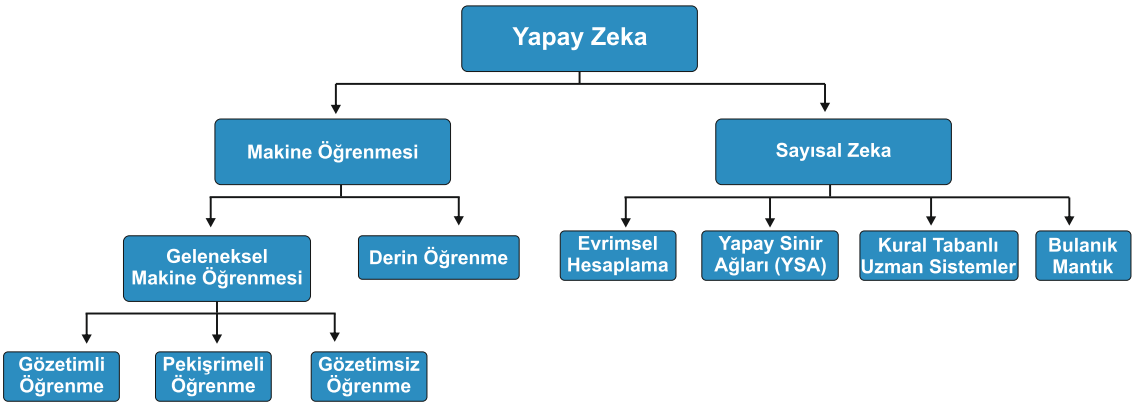
Şekil 23.2. *Yapay zekânın tarihsel gelişimi*

İkinci dalgada, derin öğrenme kullanılarak geliştirilen dar kapsamlı yapay zekâ uygulamaları, belirli, iyi tanımlanmış görevlerde ürettikleri başarılı sonuçlarla hayatın her alanında yer almaktadır. Fakat ikinci dalga yapay zekânın en önemli sorunu, çok miktarda eğitim verisine bağımlılığıdır. Örneğin, kedileri tanımak için geliştirilecek bir derin öğrenme algoritmasının kabul edilebilir bir doğruluk seviyesinde sonuç verebilmesi için on binlerce kedi fotoğrafıyla eğitilmesi gerekir. Bu üç yaşındaki bir çocuğun sadece birkaç örnek gördükten sonra başarabileceği süreçtir.

Üçüncü Dalga yapay zekâ sistemleri, özellikle bağlamsal adaptasyon yeteneklerinde dramatik iyileştirmeler içerecektir. Bağlamı ve anlamı anlayacakları için içinde bulundukları ortama ve çözülmesi gereken problemlere daha kolay adapte olup bunlara uygun çözümler üretebilecektir. Üçüncü dalga yapay zekâ sistemleri sadece kediyi tanımakla kalmayacak, aynı zamanda neden bir kedi olduğunu ve bu sonuca nasıl ulaştığını açıklayabilecektir.

Üçüncü dalga yapay zekâ sistemleri, muazzam sayıda etiketli eğitim verisi ile beslenmek yerine, insanların nasıl öğrendiklerine çok daha benzer bir şekilde öğrenme yeteneğine sahip olmaya odaklanacaktır. Bu sadece büyük veri setlerine bağımlılığı azaltmakla kalmaz, aynı zamanda yanlış/yanıltıcı eğitim verisi sorununu da giderir. Bu kapsamda derin pekiştirmeli öğrenme, etiketli veri ile çalışma bağımlılığını ortadan kaldırabilecek önemli tekniklerdendir. İnsanın öğrenmesine benzer bir yaklaşıma sahip olan derin pekiştirmeli öğrenme konusunda yapılan çalışmalar, insan düzeyi yapay zekâ alanında önemli açılımlar yapılmasını sağlayabilir.

Yapay zekânın gelişiminin kısa tarihçesini verdikten sonra şimdi de bahsettiğimiz yapay zekâ tekniklerinin neler olduğunu inceleyelim. Yapay zekâ, yöntem açısından iki ana başlıkta incelenir: "Makine Öğrenmesi" ve "Hesaplamalı Zekâ (Computational Intelligence)"



Şekil 23.3. *Yapay zekânın metodolojik taksonomisi*

Hesaplamalı zekâ, biyolojik ve dilsel olarak motive edilmiş hesaplama paradigmalarının teorisi, tasarımı, uygulaması ve geliştirilmesidir (https://cis.ieee.org/about/what-is-ci).

Hesaplamalı zekâ, 4 alt başlıkta incelenebilir:

- Kural Tabanlı Uzman Sistemler (Rule-based expert systems)
- Bulanık Mantık (Fuzzy Logic)
- Evrimsel Hesaplama (Evolutionary computation)
- Yapay Sinir Ağları (Neural Networks)

Kural tabanlı uzman sistemler, birinci dalga yapay zekâ teknolojilerinden bahsettiğimiz geleneksel programlama teknikleri kullanılarak uzmanlık gerektiren bir problemin kural tabanlı olarak çözüldüğü yapılardır.

Bulanık mantık kavramı, 1965 yılında Prof. Dr. Lotfi Zadeh'in Information and Control dergisinde bu konu üzerine ilk makalelerinin yayınlanması ile duyuldu (Zadeh, 1965). O tarihten sonra önemi gittikçe artarak günümüze kadar gelen bulanık mantık, belirsizliklerin anlatımı ve belirsizliklerle çalışılabilmesi için kurulmuş katı bir matematik düzen olarak tanımlanabilir. Uygulama alanı çok geniş olan bulanık mantığın sağladığı en büyük fayda ise "insana özgü tecrübe ile öğrenme" olayının kolayca modellenebilmesi ve belirsiz kavramların bile matematiksel olarak ifade edilebilmesine olanak tanımasıdır.

Evrimsel hesaplama, genetik kalıtım ve doğal seleksiyon gibi ilkeleri biyolojik evrim teorisine dayanan bir grup problem çözme tekniğinin genel adıdır. Bu teknikler, analitik ve tahmin algoritmaları gibi pratik endüstri uygulamalarından protein katlanması (protein folding) gibi öncü bilimsel araştırmalara kadar çeşitli problemlere uygulanmaktadır. Bu alandaki teknikler, geleneksel yaklaşımların dikkate alması için çok fazla değişkeni olan optimizasyon problemlerinde ve belirli bir problemi çözme yaklaşımının net bir şekilde belirlenemediği zamanlarda kullanılır (Mitchell & Taylor, 1999).

Makine öğrenmesi, bilgisayar sistemlerine açık bir şekilde programlanmadan veriyi "öğrenme" yeteneği vermek için istatistiksel teknikleri kullanan bir yapay zekâ alanıdır (Samuel, 1959). Makine öğrenmesi, çeşitli algoritmalar ve yöntemler ile veride bazı kalıpları arar ve bu kalıplara karşılık gelen etiketlere bakarak önce öğrenir, daha sonra (öğrendiklerine benzer durumla

karşılaştığında) deneyimlerinden yararlanarak çıkarım yapabilen sistemler geliştirmeye imkân sağlar.

Yapay zeka algoritmaları, özellikle makine öğrenmesi, büyük ölçekli omik ve çoklu omik kompleks verilerinin işlenebilirliği ve yorumlanabilmesinde en etkili araçtır. Geleneksel makine öğrenmesi algoritmaları genellikle üç şekilde sınıflandırılır (Tablo 23.1).

- Gözetimli Öğrenme (Supervised Learning)
- Gözetimsiz Öğrenme (Unsupervised Learning)
- Pekiştirmeli Öğrenme (Reinforcement Learning)

Gözetimli öğrenme, örnek girdi-çıktı veri çiftlerine dayalı olarak bir girdiyi bir çıktıya eşleyen bir fonksiyonu öğrenmeyi hedefleyen makine öğrenmesi yaklaşımıdır. [2] Gözetimli öğrenme problemleri "regresyon" ve "sınıflandırma" olarak ikiye ayrılır. Regresyon problemlerinde, girdi-çıktı veri çiftlerini sürekli fonksiyonlara eşlemeye çalışırız. Bu sayede gelecek yeni girdiler için çıktıları tahmin edebilecek bir mekanizma oluşturulmuş olur. Sınıflandırma yaklaşımında ise girdilerin, etiketlenmiş eğitim verisine benzerlikleri araştırılarak hangi sınıfa ait olduğu tahmin edilmeye çalışılır. Bu nedenle gözetimli öğrenme için doğru ve çeşitli şekilde çok sayıda verinin etiketlenip makine öğrenmesi tarafından eğitilmesi çok önemlidir. Gözetimli öğrenmede verilerin tek veya çok sayıdaki değişkenle regresyon analizini ya da karar ağacı (decision tree), rastgele orman (random forest), k-nn (en yakın komşu) ve yapay sinir ağı (artificial neural network) gibi yöntemlerle sınıflandırılır (Biswas & Chakrabarti, 2020; Lai vd., 2018; Vij vd., 2020). Omik tabanlı büyük veri ve yapay zekâya dayalı sistem biyoloji analizinde sıklıkla "supervised learning-based support vector machine (SVM)" algoritması kullanılmaktadır. SVM, farklı sınıfların örnek veri noktaları arasındaki muhtemel en uzak mesafeyi göz önünde bulundurarak hesaplama yapar. SVM dayalı metotlar, farklı kanser türlerinde histolojik olarak alt tiplerin bulunması, doku biyopsi materyali yerine moleküler özellikler kullanılarak yapılan sınıflama ve biyobelirteç belirleme alanında sıklıkla kullanılmaktadır. Random forest (RF) algoritması ise oldukça sık kullanılan bir diğer yapay zekâya dayalı sistem biyoloji analizidir. Omik ve çoklu-omik büyük veri analizinde algoritma bazı karar ağacı denilen sınıflandırma setlerinden oluşur (Biswas & Chakrabarti, 2020; Lai vd., 2018; Vij vd., 2020).

Gözetimsiz öğrenme, algoritmaya eğitim verileri için önceden atanmış herhangi bir etiket verilmediği makine öğrenmesi yaklaşımıdır. Genellikle, veri etiketlemenin çok güç ya da imkânsız olduğu durumlarda kullanılır ve doğası gereği eğitim veri setinde doğal olarak oluşan kalıpları kendi kendine keşfetmesi gerekmektedir (Hinton & Sejnowski, 1999). Otokodlayıcılar (autoencoders) gibi gözetimsiz öğrenme metotları çoklu-omik verilerinin azaltılmasında kullanılır (Franco vd., 2021; Lemsara vd., 2020; Ma & Zhang, 2019; Xiaoyu Zhang vd., 2019). Otokodlayıcılarda gereksiz veriyi ayıklamak için kodlayıcı (encoder) büyük veri girdisinden özelliklerin çıkarımını yaparken, kod çözücü (decoder) sadece bu özellikleri kullanarak girdiye oldukça benzer bir çıktı oluşturmaya çalışır (Le vd., 2020). Diğer öğrenme metotları kümeleme, DBSCAN, K-means/K-medians ve hiyerarşik gibi yöntemleri kapsamaktadır (Birant & Kut, 2007; Likas vd., 2003; Mohr vd., 2018; Rodriguez vd., 2019).

Pekiştirmeli öğrenmede, ajan adı verilen öğrenen makinemiz karşılaştığı durumlara bir tepki verir ve bunun karşılığında da sayısal bir ödül/ceza alır. Öğrenen makine aldığı bu ödül puanını azamiye çıkartmak için çalışır (Li, 2017).

Derin öğrenme, insanların nöron yapısını temel alarak algılayıcı (perceptron) ile oluşturulan tek katmanlı yapay sinir ağının, çok katmanlı hale getirilerek derin bir yapay sinir ağı haline gelmesidir. Katman sayısı ne kadar artarsa, sistem o kadar derinleşir.

Çok sayıda karmaşık ağ ve etkileşim içeren veri gruplarının analizinde makine öğrenme tekniklerinin birden fazla birleştirilmesiyle Derin Öğrenme (DL) yöntemi uygulanır. Hastalıkların teşhisi, prognozu, tedaviye cevabın monitorizasyonu, protein-küçük molekül etkileşimleri ve kişiselleştirilmiş tıp çerçevesinde kritik olan tedavi seçimi üzerine derin öğrenme yöntemleri başarıyla uygulanmaktadır (Biswas & Chakrabarti, 2020; Lai vd., 2018; Vij vd., 2020).

Makine öğrenmesi ve derin öğrenme, tıp, moleküler biyoloji ve genetik alanlarında farklı kullanım senaryolarında aktif olarak kullanılmaktadır (Tablo 23.1).

Tablo 23.1. *Geleneksel makine öğrenmesi algoritmaları ve uygulama alanları*

Gözetimli Öğrenme	• **Regresyon** • Genom çağında ilişkilendirme analizi • Dizi benzerliği Tahmini • **Sınıflandırma** • Kanserli-Sağlıklı sınıflandırması • Çok sınıflı doku sınıflandırması
Gözetimsiz Öğrenme	• **Kümeleme** • Protein ailesi kümeleme • Genlerin kromozomlara göre kümelenmesi • **Boyut İndirgeme** • Gen verisindeki aykırıların sınıflandırılması
Pekiştirmeli Öğrenme	• **Derin Pekiştirmeli Öğrenme** • Akıllı ilaç tasarımı

Yapay zekânın Sağlık ve Moleküler biyoloji alanlarındaki uygulamaları

Sağlık alandaki yapay zeka uygulamaları genel olarak üç grupta toplanmıştır: 1) Görüntü analizi ki bu alt grupta radyolojik, ultrason, patolojik, endoskopik, deri, fundus görüntü analizi ile EKG ve EEG analizleri sayılabilir. 2) Omik analizleri ki bu alt grupta da epi/genomik, epi/transkriptomik, epi/proteomik, metabolomik, lipidomik, metagenomik ve entegre omik analizleri sayılabilir. 3) Yazılı bilgi analizi ki bu alt grupta da radyoloji ve patoloji raporları, elektronik hasta ve medikal kayıtlar ile literatür taraması sayılabilir (Hamamoto vd., 2020). Klinikte de yapay zekâ son dönemlerde daha çok kullanım alanı bulmaya başlamıştır. Akut koroner hastalığı ve kalp yetmezliği riskini belirlemede (Dorado-Díaz vd., 2019; Huang vd., 2017; Mortazavi vd., 2016), atrial fibrilasyonun daha erken tespitinde (Halcox vd., 2017; Raja vd., 2019; Turakhia vd., 2019), pulmoner fonksiyon test sonuçlarının değerlendirilmesinde (Delclaux, 2019; Topalovic vd., 2019), kan glukoz düzeylerinin gerçek zamanlı olarak izlenmesinde (Lawton vd., 2018), polikistik böbrek hastalığında glomerüler filtrasyon oranındaki düşmenin tespitinde (Niel vd., 2018), ilerleyici IgA nefropatisi risk tespitinde (Geddes vd., 1998), multipl skleroz, parkinson, huntington gibi nörolojik hastalıklarda giyilebilir sensörler yardımı ile postür, yürüyüş ve tremorun değerlendirilmesinde (Dorsey vd., 2018), histopatoloji ile kanser tanısında (Campanella vd., 2019), radyolojik görüntüleme ile tanı konulmasında (Liu vd., 2019), yapay zekâ uygulamalarından daha çok yararlanmaya başlanılmıştır. Derin öğrenme tekniklerinden olan

Evrişimsel Sinir Ağları (Convolutional Neural Networks – CNN) aracılığıyla deri lezyonları (Esteva vd., 2017), akciğer kanseri (Coudray vd., 2018) ve meme kanseri metastazlarının tanı ve sınıflandırılmaları (Ehteshami Bejnordi, 2017) daha etkin olarak yapılabilmektedir (Azuaje, 2019; LeCun vd., 2015; Rawat & Wang, 2017). Ancak, henüz başlangıç safhasındaki bu uygulamaların daha çok veri setleri ve farklı demografiler ile doğrulanmaları gerekmektedir (Kelly vd., 2019; Panch vd., 2019).

Özetlemek gerekirse yapay zekâ uygulamaları, tıp doktorları için aşağıdaki faaliyetler için gerçekten yararlı asistanlar olabilirler:

- Tıbbi görüntüleme
- Erken tanı ve tanı testleri
  - Büyük veri analizi ile geniş bir hasta popülasyonundan anlamı bulgular elde etme
  - Bulgulardan ve vakalardan kendi kendine öğrenebilen sistemler
- Genom düzenleme ve büyük veri uygulamaları
- Akıllı ilaç geliştirme
- Kişiselleştirilmiş tıp uygulamaları
- Uzaktan hasta takibi – Koruyucu hekimlik uygulamaları
  - Giyilebilir teknolojiler ile tedavi hakkında akıllı geri bildirim ve olası hastalıkların tahmin edilebilmesi
  - Tedavi sırasında hastalığın durumunun ve tedavi sonucunun tahmin edilebilmesi
- Pandemik hastalıklar için risk uyarısı ve hastalık yayılım tahmini için gerçek zamanlı çıkarımlar yapılmasına yardımcı olunması
- Dergilerden, ders kitaplarından ve klinik uygulamalardan güncel tıbbi bilgilerin toplanması, özetlenmesi ve paylaşılması.

Gelecek için yapay zekâ öngörüleri

Yapay zekânın moleküler biyoloji ve tıpta daha yaygın kullanılabilmesi için aşılması gereken bazı engelleyici faktörler mevcuttur. Bunlar arasında **yetersiz veri** (Coudray vd., 2018; Esteva vd., 2017; Jordan & Mitchell, 2015; Pan & Yang, 2009; Sevakula vd., 2019; Shaikhina & Khovanova, 2017; Szegedy vd., 2016; Tan, 2016; Turki vd., 2017), **farklı yapılardaki veri tipleri ile çalışma** (Disselhorst vd., 2018; Gevaert vd., 2014; Karczewski & Snyder, 2018; Kim vd., 2015; Klughammer vd., 2018; Y. Li vd., 2018; Ramazzotti vd., 2018; Yu vd., 2017), **farklı öğrenme yaklaşımları** (Ali vd., 2018; Mahmud vd., 2018; Padmanabhan vd., 2017; Shaikhina & Khovanova, 2017; Tseng vd., 2017; Yauney & Shah, 2018) ve **analizlerin anlaşılabilir yeterlilik ve açıklıkta olmaması** (Ancona vd., 2017; Basu vd., 2018; Castelvecchi, 2016; Chen vd., 2018; Choi vd., 2016; Fabris vd., 2018; Lahav vd., 2018; O. Li vd., 2018; Lundberg vd., 2018; Michael vd., 2018) sayılabilir.

İnsanların bilişsel (Cognitive) limitleri moleküler biyoloji ve diğer biyomedikal araştırmalarda sınırlayıcı rol oynar. Yapay zekâ uygulamaları ile bu problemlerin çözülebileceğini öngörüyoruz. IBM'nin Watson bilgisayarı ile bütün literatürü tarayıp tasnif etmek amacıyla bir çalışma yapılmaktadır. IBM, Baylor Tıp Koleji ve MD Anderson Kanser Merkezi işbirliği ile Watson

bilgisayarı kullanılarak *p53* geninde yeni modifiye bölgeler tespit edildi. DARPA BMP projesi ile otomatik veri çıkarımı ile kanser ile ilişkili moleküler etkileşimleri yüksek bir oran ile tespit edildi (Cohen, 2015). Özellikle makine-öğrenme ve derin öğrenme ile insan bilişsel özelliklerinin sınırlamalarından kaynaklanan sorunların aşılması beklenmektedir. Bilgisayarların karmaşık objeleri tanıyabilecek özellikler kazanmaları sağlanabilir. Derin fenotipleme ile çok yüksek oranda doğru teşhis koyma, hasta sınıflandırma ve tam ölçüsünde klinik kararlar verme mümkün olabilecektir. Kişiye-özgü tıp, yapay zekâ ve derin öğrenme ile entegre çoklu-omik ve diğer biyolojik değerlerin birleştirilmesi ile doğru teşhis koyma, etkin tedavi uygulamaları ve hatta etkin ilaç keşfi mümkün olabilecektir.

Yapay zekâ ile her yıl 1 milyonun üzerinde yapılan bilimsel yayınlar daha kolay ve etkin bir şekilde takip edilebilir (Zhang vd., 2020). Tam tarafsızlık gerektiren durumlarda insan kaynaklı bilimsel çalışmalar tam doğruyu yansıtamayabilir. İnsanın bilişsel özelliklerinden dolayı kapasitesi sınırlıdır ve taraflı bilgi yansıtabilir ama yapay zekâ uygulamaları ile bu risk ortadan kalkar. Moleküller arasındaki ilişkilerin ve bu ilişkideki bilgi açıklarının tamamlanmasında da kullanılabilir. Hastalıkların tanısının doğru konulmasını özellikle de alt grupların özgül bir şekilde belirlenerek doğru tedavi seçeneklerinin uygulanmasını sağlar. Biyoinformatik yöntemlerle otomatik olarak geliştirilen hipotezler ile biyomedikal araştırmalar yapay zekâ ile otonom bir şekilde yapılabilir. Böylece biyomedikal araştırmalar gelecekte tahmin edemeyeceğimiz bir hızda gelişebilir. Yapay zekâ insan zekâsının en verimli bir şekilde bilimsel çalışmalarda kullanılmasını da tasarlayabilir.

Sonuç

Tıp, moleküler biyoloji, biyoteknoloji, nanoteknoloji ve bilişim teknolojileri alanındaki gelişmeler günümüzde sağlık sistemlerinin daha akıllı olarak hizmet vermesini sağlayabilecek altyapıyı kurma imkânı vermektedir. Yapay zekâ, büyük veri, entegre-çoklu-omik, biyoinformatik ve sistem biyolojisi bir arada kullanılarak sağlıklı yaşam için gerekli olan risk analizlerinin daha risk ortaya çıkmadan yapılabilmesi ve gerekli önlemlerin erkenden alınması mümkün olacaktır. Sağlıklı yaşam için bireye uygun beslenme, hastalık kaçınılmaz ise en etkin ilacın uygulanması daha etkin bir şekilde yapılabilecektir. Ayrıca, yapay zekâ ve ayrılmaz unsurları bir arada kullanılarak bilimsel deney tasarımı, verilerin otomatik olarak toplanması ve depolanması, analiz edilmesi ve sonuçların rapor edilmesi kolaylıkla mümkün olacaktır. Mevcut veriler kullanılarak ilaç adayı yeni moleküllerin keşfi ve mevcutların yeni endikasyonlar için etkinliği tasarlanabilecektir. Özellikle kişisel–omik verileri de kullanılarak kişiye-özgü etkin tasarımlar yapılabilecektir. Gelecekte multi- ve inter-disipliner ekipler ile yapılacak AR-GE çalışmalarında özellikle yapay zekâ ekipleri süreçlerin merkezinde yer alacaklardır. Bu nedenle tıp ve yaşam bilimleri ile bilişim bilimleri eğitiminin farklı uzmanlıkların aynı dili konuşabileceği, ya da en azından birbirini anlayabileceği bir formatta verilmesi mutlak gereklilik olacaktır.

Kaynakça / References

Ali, I., Hart, G. R., Gunabushanam, G., Liang, Y., Muhammad, W., Nartowt, B., ... Deng, J. (2018). Lung nodule detection via deep reinforcement learning. *Frontiers in Oncology*, *8*, 108.

Ancona, M., Ceolini, E., Öztireli, C., & Gross, M. (2017). Towards better understanding of gradient-based attribution methods for deep neural networks. *arXiv preprint arXiv:1711.06104*.

Azuaje, F. (2019). Artificial intelligence for precision oncology: beyond patient stratification. *npj Precision Oncology*, *3*(1), 6. https://doi.org/10.1038/s41698-019-0078-1

Basu, S., Kumbier, K., Brown, J. B., & Yu, B. (2018). Iterative random forests to discover predictive and stable high-order interactions. *Proceedings of the National Academy of Sciences*, *115*(8), 1943-1948.

Birant, D., & Kut, A. (2007). ST-DBSCAN: An algorithm for clustering spatial–temporal data. *Data & knowledge engineering*, *60*(1), 208-221.

Biswas, N., & Chakrabarti, S. (2020). Artificial intelligence (AI)-based systems biology approaches in multi-omics data analysis of cancer. *Frontiers in Oncology*, *10*.

Campanella, G., Hanna, M. G., Geneslaw, L., Miraflor, A., Silva, V. W. K., Busam, K. J., ... Fuchs, T. J. (2019). Clinical-grade computational pathology using weakly supervised deep learning on whole slide images. *Nature medicine*, *25*(8), 1301-1309.

Castelvecchi, D. (2016). Can we open the black box of AI? *Nature News*, *538*(7623), 20.

Chakraborty, S., Hosen, M., Ahmed, M., & Shekhar, H. U. (2018). Onco-multi-OMICS approach: a new frontier in cancer research. *BioMed research international*, *2018*.

Chen, C., Li, O., Tao, C., Barnett, A. J., Su, J., & Rudin, C. (2018). This looks like that: deep learning for interpretable image recognition. *arXiv preprint arXiv:1806.10574*.

Choi, E., Bahadori, M. T., Kulas, J. A., Schuetz, A., Stewart, W. F., & Sun, J. (2016). Retain: An interpretable predictive model for healthcare using reverse time attention mechanism. *arXiv preprint arXiv:1608.05745*.

Cohen, P. R. (2015). DARPA's Big Mechanism program. *Physical biology*, *12*(4), 045008.

Collins, F. S., Morgan, M., & Patrinos, A. (2003). The Human Genome Project: lessons from large-scale biology. *Science*, *300*(5617), 286-290.

Coudray, N., Ocampo, P. S., Sakellaropoulos, T., Narula, N., Snuderl, M., Fenyö, D., ... Tsirigos, A. (2018). Classification and mutation prediction from non–small cell lung cancer histopathology images using deep learning. *Nature medicine*, *24*(10), 1559-1567.

Delclaux, C. (2019). No need for pulmonologists to interpret pulmonary function tests. In: Eur Respiratory Soc.

Disselhorst, J. A., Krueger, M. A., Ud-Dean, S. M., Bezrukov, I., Jarboui, M. A., Trautwein, C., ... Leibfritz, D. (2018). Linking imaging to omics utilizing image-guided tissue extraction. *Proceedings of the National Academy of Sciences*, *115*(13), E2980-E2987.

Dorado-Díaz, P. I., Sampedro-Gómez, J., Vicente-Palacios, V., & Sánchez, P. L. (2019). Applications of artificial intelligence in cardiology. The future is already here. *Revista Española de Cardiología (English Edition)*, *72*(12), 1065-1075.

Dorsey, E. R., Glidden, A. M., Holloway, M. R., Birbeck, G. L., & Schwamm, L. H. (2018). Teleneurology and mobile technologies: the future of neurological care. *Nature Reviews Neurology*, *14*(5), 285-297.

Ehteshami Bejnordi, B. (2017). Veta M. Johannes van Diest P, van Ginneken B, Karssemeijer N, Litjens G, van der Laak J, the CC, Hermsen M, Manson QF et al: Diagnostic assessment of deep learning algorithms for detection of lymph node metastases in women with breast cancer. *JAMA*, *318*(22), 2199-2210.

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, *542*(7639), 115-118.

Fabris, F., Doherty, A., Palmer, D., De Magalhães, J. P., & Freitas, A. A. (2018). A new approach for interpreting random forest models and its application to the biology of ageing. *Bioinformatics*, *34*(14), 2449-2456.

Franco, E. F., Rana, P., Cruz, A., Calderón, V. V., Azevedo, V., Ramos, R. T., & Ghosh, P. (2021). Performance Comparison of Deep Learning Autoencoders for Cancer Subtype Detection Using Multi-Omics Data. *Cancers*, *13*(9), 2013.

Geddes, C. C., Fox, J. G., Allison, M. E., Boulton-Jones, J. M., & Simpson, K. (1998). An artificial neural network can select patients at high risk of developing progressive IgA nephropathy more accurately than experienced nephrologists. *Nephrology Dialysis Transplantation*, *13*(1), 67-71.

Gevaert, O., Mitchell, L. A., Achrol, A. S., Xu, J., Echegaray, S., Steinberg, G. K., ... Plevritis, S. K. (2014). Glioblastoma multiforme: exploratory radiogenomic analysis by using quantitative image features. *Radiology*, *273*(1), 168-174.

Goyal, M. R. (2018). *Scientific and Technical Terms in Bioengineering and Biological Engineering*. CRC Press.

Halcox, J. P., Wareham, K., Cardew, A., Gilmore, M., Barry, J. P., Phillips, C., & Gravenor, M. B. (2017). Assessment of remote heart rhythm sampling using the AliveCor heart monitor to screen for atrial fibrillation: the REHEARSE-AF study. *Circulation*, *136*(19), 1784-1794.

Hamamoto, R., Komatsu, M., Takasawa, K., Asada, K., & Kaneko, S. (2020). Epigenetics analysis and integrated analysis of multiomics data, including epigenetic data, using artificial intelligence in the era of precision medicine. *Biomolecules*, *10*(1), 62.

Hinton, G. E., & Sejnowski, T. J. (1999). *Unsupervised learning: foundations of neural computation*. MIT press.

Hood, L. (2013). Systems biology and p4 medicine: past, present, and future. *Rambam Maimonides medical journal*, *4*(2).

Huang, Z., Chan, T.-M., & Dong, W. (2017). MACE prediction of acute coronary syndrome via boosted resampling classification using electronic medical records. *Journal of biomedical informatics*, *66*, 161-170.

Jordan, M. I., & Mitchell, T. M. (2015). Machine learning: Trends, perspectives, and prospects. *Science*, *349*(6245), 255-260.

Karczewski, K. J., & Snyder, M. P. (2018). Integrative omics for health and disease. *Nature Reviews Genetics*, *19*(5), 299-310.

Kasztura, M., Richard, A., Bempong, N.-E., Loncar, D., & Flahault, A. (2019). Cost-effectiveness of precision medicine: a scoping review. *International journal of public health*, *64*(9), 1261-1271.

Kelly, C. J., Karthikesalingam, A., Suleyman, M., Corrado, G., & King, D. (2019). Key challenges for delivering clinical impact with artificial intelligence. *BMC medicine*, *17*(1), 1-9.

Kim, D., Joung, J.-G., Sohn, K.-A., Shin, H., Park, Y. R., Ritchie, M. D., & Kim, J. H. (2015). Knowledge boosting: a graph-based integration approach with multi-omics data and genomic knowledge for cancer clinical outcome prediction. *Journal of the American Medical Informatics Association*, *22*(1), 109-120.

Klughammer, J., Kiesel, B., Roetzer, T., Fortelny, N., Nemc, A., Nenning, K.-H., ... Peter, N. (2018). The DNA methylation landscape of glioblastoma disease progression shows extensive heterogeneity in time and space. *Nature medicine*, *24*(10), 1611-1624.

Lahav, O., Mastronarde, N., & van der Schaar, M. (2018). What is interpretable? using machine learning to design interpretable decision-support systems. *arXiv preprint arXiv:1811.10799*.

Lai, K., Twine, N., O'brien, A., Guo, Y., & Bauer, D. (2018). Artificial intelligence and machine learning in bioinformatics. *Encyclopedia of Bioinformatics and Computational Biology: ABC of Bioinformatics*, *55*, 272.

Lawton, J., Blackburn, M., Allen, J., Campbell, F., Elleri, D., Leelarathna, L., ... Hovorka, R. (2018). Patients' and caregivers' experiences of using continuous glucose monitoring to support diabetes self-management: qualitative study. *BMC endocrine disorders*, *18*(1), 1-10.

Le, V., Quinn, T. P., Tran, T., & Venkatesh, S. (2020). Deep in the Bowel: highly interpretable neural encoder-decoder networks predict gut metabolites from gut microbiome. *BMC Genomics*, *21*(4), 1-15.

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, *521*(7553), 436-444.

Lemsara, A., Ouadfel, S., & Fröhlich, H. (2020). PathME: pathway based multi-modal sparse autoencoders for clustering of patient-level multi-omics data. *BMC bioinformatics*, *21*(1), 1-20.

Li, O., Liu, H., Chen, C., & Rudin, C. (2018). Deep learning for case-based reasoning through prototypes: A neural network that explains its predictions. Proceedings of the AAAI Conference on Artificial Intelligence,

Li, Y. (2017). Deep reinforcement learning: An overview. *arXiv preprint arXiv:1701.07274*.

Li, Y., Wu, F.-X., & Ngom, A. (2018). A review on machine learning principles for multi-view biological data integration. *Briefings in bioinformatics*, *19*(2), 325-340.

Likas, A., Vlassis, N., & Verbeek, J. J. (2003). The global k-means clustering algorithm. *Pattern recognition*, *36*(2), 451-461.

Liu, X., Faes, L., Kale, A. U., Wagner, S. K., Fu, D. J., Bruynseels, A., ... Kern, C. (2019). A comparison of deep learning performance against health-care professionals in detecting diseases from medical imaging: a systematic review and meta-analysis. *The lancet digital health*, *1*(6), e271-e297.

Lundberg, S. M., Nair, B., Vavilala, M. S., Horibe, M., Eisses, M. J., Adams, T., ... Kim, J. (2018). Explainable machine-learning predictions for the prevention of hypoxaemia during surgery. *Nature biomedical engineering*, *2*(10), 749-760.

Ma, T., & Zhang, A. (2019). Integrate multi-omics data with biological interaction networks using Multi-view Factorization AutoEncoder (MAE). *BMC Genomics*, *20*(11), 1-11.

Mahmud, M., Kaiser, M. S., Hussain, A., & Vassanelli, S. (2018). Applications of deep learning and reinforcement learning to biological data. *IEEE transactions on neural networks and learning systems*, *29*(6), 2063-2079.

Meric-Bernstam, F., Brusco, L., Shaw, K., Horombe, C., Kopetz, S., Davies, M. A., ... Ueno, N. (2015). Feasibility of large-scale genomic testing to facilitate enrollment onto genomically matched clinical trials. *Journal of clinical oncology*, *33*(25), 2753.

Michael, K. Y., Ma, J., Fisher, J., Kreisberg, J. F., Raphael, B. J., & Ideker, T. (2018). Visible machine learning for biomedicine. *Cell*, *173*(7), 1562-1565.

Mitchell, M., & Taylor, C. E. (1999). Evolutionary computation: an overview. *Annual Review of Ecology and Systematics*, *30*(1), 593-616.

Mohr, F., Wever, M., & Hüllermeier, E. (2018). ML-Plan: Automated machine learning via hierarchical planning. *Machine Learning*, *107*(8), 1495-1515.

Mortazavi, B. J., Downing, N. S., Bucholz, E. M., Dharmarajan, K., Manhapra, A., Li, S.-X., ... Krumholz, H. M. (2016). Analysis of machine learning techniques for heart failure readmissions. *Circulation: Cardiovascular Quality and Outcomes*, *9*(6), 629-640.

Nalbantoglu, S., & Karadag, A. (2019). Introductory chapter: insight into the OMICS technologies and molecular medicine. In *Molecular Medicine*. IntechOpen.

Nalbantoglu, S., & Karadag, A. (2021). Metabolomics bridging proteomics along metabolites/oncometabolites and protein modifications: paving the way toward integrative multiomics. *Journal of pharmaceutical and biomedical analysis*, 114031.

Niel, O., Boussard, C., & Bastard, P. (2018). Artificial Intelligence Can Predict GFR Decline During the Course of ADPKD. *American journal of kidney diseases: the official journal of the National Kidney Foundation*, *71*(6), 911-912.

Öztemel, E. (2003). Yapay sinir ağlari. *PapatyaYayincilik, Istanbul*.

Padmanabhan, R., Meskin, N., & Haddad, W. M. (2017). Reinforcement learning-based control of drug dosing for cancer chemotherapy treatment. *Mathematical biosciences*, *293*, 11-20.

Pan, S. J., & Yang, Q. (2009). A survey on transfer learning. *IEEE Transactions on knowledge and data engineering*, *22*(10), 1345-1359.

Panch, T., Mattie, H., & Celi, L. A. (2019). The "inconvenient truth" about AI in healthcare. *NPJ digital medicine*, *2*(1), 1-3.

Prasad, V. (2016). Perspective: The precision-oncology illusion. *Nature*, *537*(7619), S63-S63.

Raja, J. M., Elsakr, C., Roman, S., Cave, B., Pour-Ghaz, I., Nanda, A., ... Khouzam, R. N. (2019). Apple watch, wearables, and heart rhythm: where do we stand? *Annals of translational medicine*, *7*(17).

Ramazzotti, D., Lal, A., Wang, B., Batzoglou, S., & Sidow, A. (2018). Multi-omic tumor data reveal diversity of molecular mechanisms that correlate with survival. *BioRxiv*, 267245. https://doi.org/10.1101/267245

Rao, A. S., & Verweij, G. (2017). Sizing the prize: What's the real value of AI for your business and how can you capitalise. *PwC Publication, PwC*, 1-30.

Rawat, W., & Wang, Z. (2017). Deep convolutional neural networks for image classification: A comprehensive review. *Neural computation*, *29*(9), 2352-2449.

Rodriguez, M. Z., Comin, C. H., Casanova, D., Bruno, O. M., Amancio, D. R., Costa, L. d. F., & Rodrigues, F. A. (2019). Clustering algorithms: A comparative approach. *PloS one*, *14*(1), e0210236.

Russell, S., & Norvig, P. (2002). Artificial intelligence: a modern approach.

Samuel, A. L. (1959). Some studies in machine learning using the game of checkers. *IBM Journal of research and development*, *3*(3), 210-229.

Sevakula, R. K., Singh, V., Verma, N. K., Kumar, C., & Cui, Y. (2019). Transfer Learning for Molecular Cancer Classification Using Deep Neural Networks. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, *16*(6), 2089-2100. https://doi.org/10.1109/TCBB.2018.2822803

Shaikhina, T., & Khovanova, N. A. (2017). Handling limited datasets with neural networks in medical applications: A small-data approach. *Artificial intelligence in medicine*, *75*, 51-63.

Sonis, S., & Villa, A. (2019). *Translational systems medicine and oral disease*. Academic Press.

Subramanian, I., Verma, S., Kumar, S., Jere, A., & Anamika, K. (2020). Multi-omics data integration, interpretation, and its application. *Bioinformatics and biology insights*, *14*, 1177932219899051.

Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the inception architecture for computer vision. Proceedings of the IEEE conference on computer vision and pattern recognition,

Tan, M. (2016). Prediction of anti-cancer drug response by kernelized multi-task learning. *Artificial intelligence in medicine*, *73*, 70-77.

Topalovic, M., Das, N., Burgel, P.-R., Daenen, M., Derom, E., Haenebalcke, C., ... Louis, R. (2019). Artificial intelligence outperforms pulmonologists in the interpretation of pulmonary function tests. *European Respiratory Journal*, *53*(4).

Tseng, H. H., Luo, Y., Cui, S., Chien, J. T., Ten Haken, R. K., & Naqa, I. E. (2017). Deep reinforcement learning for automated radiation adaptation in lung cancer. *Medical physics*, *44*(12), 6690-6705.

Turakhia, M. P., Desai, M., Hedlin, H., Rajmane, A., Talati, N., Ferris, T., ... Kowey, P. (2019). Rationale and design of a large-scale, app-based study to identify cardiac arrhythmias using a smartwatch: The Apple Heart Study. *American heart journal*, *207*, 66-75.

Turki, T., Wei, Z., & Wang, J. T. (2017). Transfer learning approaches to improve drug sensitivity prediction in multiple myeloma patients. *IEEE Access*, *5*, 7381-7393.

Vij, A., Saini, S., & Bathla, R. (2020). Big Data in Healthcare: Technologies, Need, Advantages, and Disadvantages. 2020 8th International Conference on Reliability, Infocom Technologies and Optimization (Trends and Future Directions)(ICRITO),

Watson, J. D. (1970). Molecular biology of the gene. *Molecular biology of the gene*.(2nd edn).

Yauney, G., & Shah, P. (2018). Reinforcement learning with action-derived rewards for chemotherapy and clinical trial dosing regimen selection. Machine Learning for Healthcare Conference,

Yu, K.-H., Berry, G. J., Rubin, D. L., Re, C., Altman, R. B., & Snyder, M. (2017). Association of omics features with histopathology patterns in lung adenocarcinoma. *Cell systems*, *5*(6), 620-627. e623.

Zadeh, L. A. (1965). Information and control. *Fuzzy sets*, *8*(3), 338-353.

Zhang, X., Yang, H., & Zhang, R. (2019). Challenges and future of precision medicine strategies for breast cancer based on a database on drug reactions. *Bioscience reports*, *39*(9).

Zhang, X., Zhang, J., Sun, K., Yang, X., Dai, C., & Guo, Y. (2019). Integrated multi-omics analysis using variational autoencoders: Application to pan-cancer classification. 2019 IEEE International Conference on Bioinformatics and Biomedicine (BIBM),

Zhang, Y., Liang, S., Feng, Y., Wang, Q., Sun, F., Chen, S., ... Pan, H. (2020). A Research Protocol for a Systematic Review of Automatic Literature Screening in Medical Evidence Synthesis.

Doç. Dr. ABDULLAH KARADAĞ | TUBITAK Marmara Araştırma Merkezi | abdullah.karadag[at]tubitak.gov.tr | ORCID: 0000-0003-0969-7038

Dr. Abdullah Karadağ, İstanbul Üniversitesi Cerrahpaşa Tıp Fakültesi'ni 1987 yılında bitirdikten sonra Sağlık Bakanlığı bünyesinde bir süre hekim olarak görev yapmıştır. Aydın Adnan Menderes Üniversitesi Tıp Fakültesi adına İngiltere'ye giden Dr. Karadağ 2000 yılında University of Sheffield Medical School'da moleküler onkoloji odaklı doktora çalışmalarını tamamlayarak doktora sonrası çalışmalarda bulunmak üzere Amerika'ya gitmiştir. National Institutes of Health bünyesinde SIBLING moleküllerinin osteotropik kanserlerin ilerlemesi üzerindeki rollerini incelemiştir. Bu süreçte Johns Hopkins University Whiting School of Engineering Computer Science bölümünden Master derecesi almıştır. Daha sonra tekrar İngiltere'ye dönen Dr. Karadağ University of Sheffield Medical School'da akademisyen olarak bir süre görev yapmıştır. Dr. Karadağ 20 yıla yakın bir aradan sonra TÜBİTAK MAM Başkanı'nın daveti ile 2012 yılında Türkiye'ye dönerek çalışmalarına halen orada devam etmektedir. Dr. Karadağ 30 yıla yaklaşan kariyerinde tamamen kanser çalışmalarına odaklanmıştır. Özellikle tümör hücresi ile mikroçevresi arasındaki ilişki, kemik metastazları, metastatik kaskad, biyobelirteç, biyoinformatik ve CAR-T hücre tedavi sistemleri odaklı olarak çalışmaktadır. Halen TÜBİTAK MAM'da Moleküler Onkoloji Laboratuvarı'nın sorumluluğunu yürüten Dr. Karadağ farklı hedeflere yönelik olarak hematolojik kanserler ve akciğer kanseri için CAR-T hücre tedavi sistemi geliştirme çalışmalarına devam etmektedir. Dr. Karadağ evli ve 2 çocuk babasıdır.

Assoc. Prof. ABDULLAH KARADAĞ | TUBITAK Marmara Research Center | abdullah.karadag[at]tubitak.gov.tr | ORCID: 0000-0003-0969-7038

Dr. Abdullah Karadağ obtained his MD degree from İstanbul University Cerrahpaşa Medical Faculty in 1987. After working as a Doctor for the Ministry of Health for a few years he joined Adnan Menderes Medical Faculty in 1993 and then moved to the UK for PhD studies. Dr. Karadağ completed his PhD studies on multiple myeloma bone disease at the University of Sheffield Medical School in 2000 and then moved to the National Institutes of Health, US as a Research Fellow to study the role of SIBLING proteins in osteotropic cancer progression. Dr. Karadağ has also obtained an MSc degree in Computer Science (with Bioinformatics option) from the Johns Hopkins University Whiting School of Engineering during his fewllowship. Dr Karadağ returned back to the University of Sheffield to study prostate cancer bone disease in 2005. After an invitation from the head of TÜBİTAK Marmara Research Center Dr. Karadağ has returned to his native Türkiye in 2012 and estalished Molecular Oncology Laboratory. Dr. Karadağ is currently leading oncology research at the center where he also served as a Deputy Director for 7 years. Dr. Karadağ has focused on cancer research throughout his career with achievements of many high-impact publications and awards. Dr. Karadağ is currently focused the development of CAR-T cell therapy systems for hematological cancers and lung cancer. Dr. Karadağ is married with 2 children.

24. MİKROORGANİZMA GENETİĞİ

24. MICROORGANISMS GENETICS

Prof. Dr. Recep Öztürk